

座位号:

考场号:

学号:

姓名:

题

答

得

不

内

线

封

密



《机器学习》期末考试复习样卷

第一章——绪论

中国科学技术大学 信息科学技术学院

学校: 中国科学技术大学

学院: 信息科学技术学院

学期: 26 春

课程编号: EE3502.01

授课教师: 肖力

助教: 陈璟皓 PB23010359

日期: 2026 年 6 月 18 日

时长: 2 小时

适用说明:

1. 本卷对应第 1 章绪论, 范围为 1.1–1.4; 1.5–1.7 不列入考查。
2. 选择题含单选与多选, 判断题只需判断正误; 简答题重在概念准确、层次清楚, 计算题需写出关键步骤。
3. 默认符号约定与课堂讲义一致。若题中另有说明, 以题中设定为准。

一、选择题

1.1 单选题

1. 【单选】机器学习中的“学习”更准确地说是指 ()。
A. 将训练样本逐条存入数据库, 并在测试时查表
B. 通过人工枚举规则, 完全避免统计推断
C. 从数据中获得模型, 使其能对未见样本作出较好判断
D. 只要训练误差为零, 就必然获得正确规律

参考答案: C。机器学习强调从数据中产生模型, 并使模型能在新的样本上作出较好的预测或判断。

注: 本题考察机器学习的基本含义, 学习、经验与模型的关系; 见教材 p1。

2. 【单选】一个数据集由若干西瓜记录组成, 每条记录包含“色泽、根蒂、敲声”等取值。这里的一条记录通常称为 ()。
A. 属性值 B. 样本或示例 C. 属性空间 D. 训练算法

参考答案: B。数据集中的一条记录对应一个样本, 也常称为一个示例或实例。

注：本题考察数据集、样本、示例、属性值等基本术语；见教材 p2。

3. 【单选】关于分类、回归与聚类，下列说法正确的是 ()。

- A. 分类的输出为连续值，回归的输出为离散类别
- B. 聚类必须依赖人工给出的类别标记
- C. 二分类任务中通常可指定正类与反类
- D. 多分类任务只能由多个二分类任务拼接得到

参考答案：C。分类输出离散类别，回归输出连续值；聚类通常不依赖标记；多分类可以作为独立任务处理，并不必须由二分类拼接而成。

注：本题考察分类、回归、二分类、多分类与聚类的定义；见教材 p3。

4. 【单选】设学习任务有 3 个离散属性，其可取值个数分别为 3、2、2。若假设由各属性上的具体取值或通配符“*”构成，并额外加入一个空假设，则假设空间大小为 ()。

- A. $3 \times 2 \times 2$
- B. $(3 + 2 + 2) + 1$
- C. $(3 + 1) + (2 + 1) + (2 + 1) + 1$
- D. $(3 + 1)(2 + 1)(2 + 1) + 1$

参考答案：D。每个属性除具体取值外还可取通配符“*”，故非空合取假设数为 $(3+1)(2+1)(2+1)$ ，再加空假设得到选项 D。

注：本题考察离散属性下的假设空间计数，通配符与空假设；见教材 p4-5。


5. 【单选】下列关于归纳与演绎的表述正确的是 ()。

- A. 归纳是从特殊事实概括一般规律，演绎是由一般规律推出具体结论
- B. 归纳只用于数学证明，演绎只用于机器学习
- C. 归纳不需要训练样本，演绎必须依赖测试样本
- D. 归纳总能得到唯一正确的目标函数

参考答案：A。机器学习更接近归纳过程，即从训练样本中概括规律；演绎则由一般性规律推出特定事实。

注：本题考察归纳与演绎的区别，机器学习中的归纳学习；见教材 p4。

6. 【单选】图中曲线 A 与 B 均能较好地解释训练样本。若某学习算法优先选择更平滑的曲线 A，这主要体现了该算法的 ()。



- A. 训练误差 B. 测试样本数量 C. 归纳偏好 D. 标记空间大小

参考答案：C。在多个假设都能解释训练样本时，算法对某类假设的优先选择就是归纳偏好。偏好平滑曲线是一种典型的归纳偏好。

注：本题考察归纳偏好的含义，多个一致假设之间的选择；见教材 p6-8。

1.2 多选题

7. 【多选】关于基本术语，下列说法正确的有 ()*。

- A. 属性也可称为特征，属性的取值称为属性值
B. 由属性张成的空间可称为样本空间、属性空间或输入空间
C. 一个样本在属性空间中的表示可看作特征向量
D. 维数通常指数据集中样本的总数

参考答案：ABC。维数通常对应属性或特征的个数，而不是样本总数。

注：本题考察属性、属性值、样本空间、特征向量与维数；见教材 p2-3。

8. 【多选】关于训练数据、测试数据与泛化，下列说法正确的有 ()*。

- A. 训练集用于学得模型，测试样本常用于评估模型对未见样本的判断能力
B. 泛化能力好等价于模型在训练集上完全正确
C. 若样本独立同分布地来自某个未知分布，训练样本可为学习总体规律提供线索
D. 标记空间是所有可能输出标记的集合

参考答案：ACD。训练集表现好并不等价于泛化能力好；机器学习关注的是模型对未见样本的判断能力。

注：本题考察训练集、测试样本、泛化能力、标记空间与独立同分布假设；见教材 p2-3。

9. 【多选】下列任务通常属于监督学习的有 ()*。

- A. 判断一封邮件是否为垃圾邮件
- B. 根据未标记样本自动划分客户群体
- C. 根据房屋信息预测成交价格
- D. 在没有标签的图像库中发现相似图片簇

参考答案：AC。垃圾邮件识别是分类任务，房价预测是回归任务，二者通常需要带标记样本；客户划分与相似图片簇发现更接近聚类，通常属于无监督学习。

注：本题考察监督学习与无监督学习，分类、回归、聚类的任务边界；见教材 p3。

10. 【多选】关于假设空间与版本空间，下列说法正确的有 ()*。

- A. 假设空间只包含已经被训练样本证明为真的假设
- B. 版本空间由与训练集一致的假设组成
- C. 随着训练样本增加，版本空间通常会被进一步缩小
- D. 若版本空间含有多个假设，说明当前训练集尚不足以唯一确定目标概念

参考答案：BCD。假设空间是学习算法可能考虑的候选假设集合，并不要求其中每个假设都已被训练样本验证为真。

注：本题考察假设空间与版本空间的定义，训练样本对候选假设的约束作用；见教材 p5-6。

11. 【多选】关于“没有免费的午餐”定理，下列理解正确的有 ()*。

- A. 其结论依赖于对所有可能目标函数的平均考察
- B. 它说明任何算法在任意具体任务上都不可能优于另一算法
- C. 它提醒我们不能脱离具体问题笼统比较算法优劣
- D. 实际问题若具有特定结构，合适的归纳偏好仍可能带来优势

参考答案：ACD。NFL 定理强调在所有可能目标函数上均匀平均时，不同学习算法的期望性能相同；它并不否认算法在具体问题上存在差异。

注：本题考察没有免费的午餐定理及其适用前提，算法比较与问题结构的关系；见教材 p8-9。

二、判断题

1. 训练集是用于训练模型的数据集合，其中每个带有标记信息的样本通常称为一个样例。 ()

参考答案：对。训练集由训练样本组成，带有标记信息的样本通常称为样例。

注：本题考察训练集、训练样本、标记与样例；见教材 p2-3。

2. 样本空间的维数通常由属性个数决定，而不是由样本总数决定。（ ）

参考答案：对。每个样本可表示为属性空间中的一个特征向量，维数对应属性或特征个数。

注：本题考察属性空间与维数；见教材 p2。

3. 回归任务的输出通常是连续值，分类任务的输出通常是离散类别。（ ）

参考答案：对。这是区分回归与分类的基本标准。

注：本题考察分类任务与回归任务的输出形式；见教材 p3。

4. 聚类任务在训练阶段通常不使用样本标记，因此一般归入无监督学习。（ ）

参考答案：对。聚类希望根据样本自身相似性形成簇，通常不依赖预先给定的类别标记。

注：本题考察聚类任务与无监督学习；见教材 p3。

5. 只要某个假设在训练集上的错误更少，它的归纳偏好就一定更适合当前真实问题。（ ）

参考答案：错。训练集表现并不能单独保证真实问题上的泛化效果；归纳偏好是否合适取决于它是否与问题本身的结构相匹配。

注：本题考察归纳偏好、泛化与训练集一致性之间的区别；见教材 p6-9。

6. “没有免费的午餐”定理并不否认算法在具体问题上的差异；它强调的是平均到所有可能问题时的等价性。（ ）

参考答案：对。NFL 定理的平均意义非常关键，不能将其误解为所有算法在每个实际任务上都相同。

注：本题考察 NFL 定理的平均意义及常见误读；见教材 p8-9。

三、简答题

1. 说明数据集、样本、属性、属性值、标记与样例之间的关系。可结合“西瓜是否好瓜”的例子作答。

参考答案：数据集由若干样本组成，样本也称示例或实例。描述样本性质的量称为属性或特征，属性的具体取值称为属性值。若样本带有关于任务输出的信息，该信息称为标记；带标记的样本可称为样例。例如一个西瓜的“色泽 = 青绿、根蒂 = 蜷缩、敲声 = 浊响”是一条样本描述，“好瓜 = 是”是标记。

注：本题考察机器学习基本术语的相互关系，尤其是样本描述与标记的区分；见教材 p2-3。

2. 比较分类、回归与聚类三类任务的目标，并说明它们与监督学习、无监督学习之间的关系。

参考答案：分类学习离散类别输出，如“好瓜/坏瓜”；回归学习连续值输出，如预测密度或价格；聚类将未标记样本划分为若干簇，使同簇样本更相似、异簇样本更不同。分类和回归通常属于监督学习，聚类通常属于无监督学习。

注：本题考察分类、回归、聚类的目标差异，以及监督学习和无监督学习的对应关系；见教材 p3。

3. 什么是假设空间与版本空间？为什么有限训练集通常不能唯一确定目标概念？

参考答案：假设空间是学习算法可能考虑的候选假设集合。版本空间是在给定训练集上仍然一致的候选假设集合。有限训练集只能约束已观察到的样本情形，未观察区域仍可能对应多个不同假设，因此通常不能唯一确定目标概念。

注：本题考察概念学习中的候选假设、与训练集一致的假设集合，以及有限样本导致的不确定性；见教材 p4-6。

4. 解释归纳偏好的含义，并说明它与奥卡姆剃刀、“没有免费的午餐”定理之间的关系。

参考答案：归纳偏好是学习算法在多个与训练集一致的假设之间作选择时表现出的偏向。奥卡姆剃刀可理解为一种常见偏好，即在解释能力相当时倾向简单假设。没有免费的午餐定理表明，若对所有可能问题均匀平均，不存在普遍优于其他算法的学习器；但在具体任务中，若偏好与问题结构相匹配，算法仍可能表现更好。

注：本题考察归纳偏好、奥卡姆剃刀与 NFL 定理之间的逻辑关系；见教材 p6-9。

四、计算题

1. 某概念学习任务使用 3 个离散属性：

属性	色泽	根蒂	敲声
可取值个数	3	3	3

假设由每个属性上的一个具体取值或通配符“*”组成，并额外包含一个空假设。训练集如下：

编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	浊响	是
3	青绿	稍蜷	清脆	否
4	浅白	蜷缩	沉闷	否

求该假设空间大小，并列出具与训练集一致的版本空间。

参考答案：每个属性可取一个具体值或通配符“*”，因此非空合取假设共有

$$(3+1)(3+1)(3+1) = 64$$

个；再加空假设，假设空间大小为 65。

由两个正例可知，色泽必须取“*”，根蒂可为“蜷缩”或“*”，敲声可为“浊响”或“*”。候选一致形式为

$$(*, \text{蜷缩}, \text{浊响}), (*, *, \text{浊响}), (*, \text{蜷缩}, *), (*, *, *).$$

第 3 个反例要求根蒂或敲声至少有一项排斥它；第 4 个反例要求敲声必须排斥“沉闷”。故版本空间为

$$\{(*, \text{蜷缩}, \text{浊响}), (*, *, \text{浊响})\}.$$

注：本题考察假设空间大小计算，正例与反例对版本空间的筛选；见教材 p4-6。

2. 设输入空间为 $\mathcal{X} = \{x_1, x_2, x_3\}$ ，二分类标记为 $\{0, 1\}$ 。训练集只给出 $f(x_1) = 1, f(x_2) = 0$ ，测试分布将全部概率放在 x_3 上。算法 $\mathcal{L}_a$ 预测 $\hat{f}_a(x_3) = 0$ ，算法 $\mathcal{L}_b$ 预测 $\hat{f}_b(x_3) = 1$ 。

候选目标函数	$f(x_1)$	$f(x_2)$	$f(x_3)$
f_1	1	0	0
f_2	1	0	1

若在两个与训练集一致的目标函数上取均匀平均，分别计算两种算法在测试点上的平均 0-1 错误，并解释其含义。

参考答案：对算法 $\mathcal{L}_a$ ，若真实函数为 f_1 ，预测正确；若为 f_2 ，预测错误，因此平均测试错误为

$$\frac{0+1}{2} = \frac{1}{2}.$$

对算法 $\mathcal{L}_b$ ，若真实函数为 f_1 ，预测错误；若为 f_2 ，预测正确，因此平均测试错误同样为

$$\frac{1+0}{2} = \frac{1}{2}.$$

这说明在没有关于未观测样本的额外偏好或先验时，仅凭当前训练集无法判定哪种预测更优；若实际问题存在结构性规律，合适的归纳偏好才会产生优势。

注：本题考察 0-1 错误的计算，NFL 定理的简化管理解，未观测样本上的归纳偏好；见教材 p8-9。