

座位号:

考场号:

学号:

姓名:

题

答

得

不

内

线

封

密



《机器学习》期末考试复习样卷

第二章——模型评估与选择

中国科学技术大学 信息科学技术学院

学校: 中国科学技术大学

学院: 信息科学技术学院

学期: 26 春

课程编号: EE3502.01

授课教师: 肖力

助教: 陈璟皓 PB23010359

日期: 2026 年 6 月 18 日

时长: 2 小时

适用说明:

1. 本卷依据当前上传内容命题, 范围为 2.1–2.3、2.5; 2.4 与 2.6 不列入考查。
2. 选择题含单选与多选, 判断题只需判断正误; 简答题重在概念准确、层次清楚, 计算题需写出关键步骤。
3. 默认正类记为 1, 反类记为 0。若题中另有说明, 以题中设定为准。

一、选择题

1.1 单选题

1. 【单选】关于经验误差、泛化误差与测试误差, 下列说法正确的是 ()。
 - A. 经验误差是在训练集上的误差, 泛化误差是在新样本上的期望误差
 - B. 训练误差越小, 泛化误差必然越小
 - C. 测试误差就是学习算法在所有未来样本上的真实误差
 - D. 泛化误差可以通过训练集准确地直接计算出来

参考答案: A。经验误差对应训练集, 泛化误差对应未知新样本上的期望表现; 测试误差只能作为对泛化能力的估计, 不能等同于真实泛化误差。

注: 本题考察经验误差、测试误差与泛化误差的区别; 见教材 p23–24。

2. 【单选】模型在训练集上表现很好, 但在测试集上表现明显变差, 这通常称为 ()。
 - A. 欠拟合
 - B. 过拟合
 - C. 留出法
 - D. 交叉验证

参考答案：B。过拟合指模型把训练样本自身的特点学得过于细，导致对未见样本的泛化能力下降。

注：本题考察过拟合的含义及其与泛化能力的关系；见教材 p23-24。

3. 【单选】关于偏差与方差分解，下列说法正确的是 ()。

- A. 偏差刻画学习算法期望预测与真实结果之间的偏离程度
- B. 方差只由样本噪声决定，与训练集扰动和学习算法无关
- C. 模型复杂度越高，偏差和方差都会单调降低
- D. 噪声可以通过增加模型复杂度完全消除

参考答案：A。偏差刻画学习算法期望预测与真实结果的偏离，方差刻画同样大小的训练集发生扰动时学习结果的变化；噪声反映问题本身的不可约误差。

注：本题考察偏差、方差、噪声及其与泛化误差的关系；见教材 p44-46。

4. 【单选】在留出法中，若原始数据集类别分布明显不均衡，较合适的划分方式是 ()。

- A. 随机划分一次即可，不必考虑类别比例
- B. 先将少数类全部放入测试集，以保证测试难度
- C. 采用分层采样，使训练集和测试集尽量保持原有类别比例
- D. 将训练集和测试集完全重合，以减少样本浪费

参考答案：C。留出法通常希望训练集与测试集的数据分布尽可能一致，类别不均衡时应优先采用分层采样。

注：本题考察留出法的划分原则，尤其是类别比例保持；见教材 p25-26。

5. 【单选】关于 k 折交叉验证，下列说法正确的是 ()。

- A. 每次使用 $1/k$ 的样本训练模型，剩余样本测试
- B. 每次使用 $k-1$ 个互斥子集训练，剩余一个子集测试
- C. 只能取 $k=2$ ，否则不同折之间会发生样本重叠
- D. 训练集和测试集在每一轮都完全相同

参考答案：B。 k 折交叉验证把数据划分为 k 个大小相近、互斥的子集，每次用 $k-1$ 个子集训练，用剩余一个子集测试。

注：本题考察 k 折交叉验证的基本流程；见教材 p26。

6. 【单选】自助法从含 m 个样本的数据集中有放回地采样 m 次。随着 m 增大, 某个样本始终未被抽中的概率趋近于 ()。

A. 0 B. $1/2$ C. $1/e$ D. 1

参考答案: C。某个样本未被抽中的概率为 $(1-1/m)^m$, 当 $m \rightarrow \infty$ 时趋近于 $1/e \approx 0.368$ 。

注: 本题考察自助法及包外样本比例的来源; 见教材 p27-28。

7. 【单选】关于模型选择中的参数调节, 下列做法最合适的是 ()。

A. 用测试集反复调参, 直到测试误差最低
B. 将训练集再划分出验证集, 用验证集辅助调参, 测试集只用于最终评估
C. 不需要验证集, 训练误差最低的参数一定最好
D. 调参阶段必须丢弃全部训练样本, 只保留测试样本

参考答案: B。测试集应尽量只用于最终性能评估; 参数选择通常借助验证集完成, 以降低对测试集的间接过拟合。

注: 本题考察模型选择、参数调节与验证集的作用; 见教材 p28。

8. 【单选】在正类极少的疾病筛查任务中, 若模型把所有样本都判为反类, 则准确率可能很高。此时更应重点考察 ()。

A. 查准率、查全率与 F_1 B. 训练轮数
C. 数据文件大小 D. 属性空间维数

参考答案: A。在类别严重不平衡时, 准确率可能掩盖少数类识别失败的问题, 查准率、查全率及其综合指标更能反映正类识别效果。

注: 本题考察类别不平衡下准确率的局限, 查准率、查全率与 F_1 的作用; 见教材 p29-32。

9. 【单选】关于 ROC 曲线, 下列说法正确的是 ()。

A. 横轴通常为真正例率, 纵轴通常为假正例率
B. ROC 曲线只适用于没有排序或评分输出的分类器
C. ROC 曲线反映分类阈值变化时真正例率与假正例率之间的关系
D. AUC 越小, 分类器排序性能通常越好

参考答案: C。ROC 曲线以假正例率为横轴、真正例率为纵轴, 刻画阈值移动时二者的变化; AUC 越大, 排序性能通常越好。

注: 本题考察 ROC 曲线、阈值移动与 AUC 的基本含义; 见教材 p33-35。

1.2 多选题

10. 【多选】关于过拟合与欠拟合，下列说法正确的有 ()*。

- A. 过拟合通常表现为训练误差小而泛化能力差
- B. 欠拟合通常说明模型对训练样本的一般性质也未学好
- C. 过拟合只要继续增加训练轮数就一定可以消除
- D. 模型选择的目标之一是在拟合能力与泛化能力之间取得平衡

参考答案：ABD。继续训练可能加重过拟合；缓解过拟合通常需要合适的模型复杂度、正则化、数据量或验证策略。

注：本题考察过拟合、欠拟合以及模型选择的基本目标；见教材 p23-24。

11. 【多选】关于留出法、交叉验证法和自助法，下列说法正确的有 ()*。

- A. 留出法通常需要保持训练集与测试集分布尽可能一致
- B. k 折交叉验证会训练 k 个模型，并将 k 次测试结果取平均
- C. 留一法是 k 折交叉验证在 $k = m$ 时的特例
- D. 自助法生成的训练集一定包含原始数据集中的每一个样本

参考答案：ABC。自助法是有放回采样，某些原始样本可能不会出现在采样得到的训练集中，这些样本可作为包外样本参与评估。

注：本题考察常用评估方法的流程与差异；见教材 p25-28。

12. 【多选】关于测试集和验证集，下列说法正确的有 ()*。

- A. 测试集应尽量模拟未来未见样本，用于最终性能评估
- B. 验证集可用于选择模型结构或超参数
- C. 反复根据测试集表现修改模型，会使测试误差估计偏乐观
- D. 测试集越小，测试误差估计通常越稳定

参考答案：ABC。测试集过小会使估计方差增大，结果通常更不稳定。

注：本题考察测试集、验证集与模型选择过程中的数据使用边界；见教材 p24-28。

13. 【多选】在二分类混淆矩阵中，下列等式正确的有 ()*。

- A. $P = \frac{TP}{TP + FP}$
- B. $R = \frac{TP}{TP + FN}$
- C. $FPR = \frac{FP}{TN + FP}$
- D. $TPR = \frac{TN}{TN + FP}$

参考答案：ABC。真正例率 TPR 与查全率相同，应为 $TP/(TP + FN)$ ；选项 D 给出的是真反例率。

注：本题考察混淆矩阵、查准率、查全率、TPR 与 FPR 的定义；见教材 p30-33。

14. 【多选】关于 $P-R$ 曲线和 F_β ，下列说法正确的有 ()*。

- A. $P-R$ 曲线可展示阈值变化下查准率与查全率的关系
- B. F_1 是查准率与查全率的调和平均
- C. 当 $\beta > 1$ 时， F_β 更重视查全率
- D. 平衡点 BEP 总是等于分类准确率

参考答案：ABC。BEP 是 $P = R$ 时的取值，并不等同于准确率。

注：本题考察 $P-R$ 曲线、BEP、 F_1 与 F_β 的含义；见教材 p30-32。

15. 【多选】关于 ROC、AUC 与代价敏感错误率，下列说法正确的有 ()*。

- A. ROC 曲线的横轴是 FPR，纵轴是 TPR
- B. AUC 可理解为 ROC 曲线下方的面积
- C. 当不同错误代价不同时，仅比较错误率可能不够
- D. 代价矩阵只会改变模型训练时间，不会影响性能度量

参考答案：ABC。代价矩阵会改变错误的评价权重，因而会影响代价敏感性能度量。

注：本题考察 ROC、AUC 以及非均等错误代价下的性能评估；见教材 p33-36。

二、判断题

1. 训练误差为零并不保证泛化误差也为零。 ()

参考答案：对。训练误差只反映模型在训练样本上的表现，泛化误差关注未见样本，二者可能有明显差异。

注：本题考察训练误差与泛化误差的区别；见教材 p23-24。

2. 偏差主要刻画期望预测与真实结果的偏离，方差主要刻画训练集扰动造成的预测波动。 ()

参考答案：对。偏差反映学习算法本身的拟合能力，方差反映数据扰动对学习结果稳定性的影响，二者共同影响期望泛化误差。

注：本题考察偏差与方差的直观含义；见教材 p44-46。

3. 测试集可以在调参过程中反复使用，只要最后报告的是最低测试误差即可。 ()

参考答案：错。反复使用测试集会把测试集信息泄漏到模型选择过程中，使最终测试误差偏乐观。

注：本题考察测试集在模型选择中的使用边界；见教材 p24-28。

4. 留一法每次只留下一个样本用于测试，因此训练集与原始数据集最相似，但计算开销通常较大。 ()

参考答案：对。留一法是 m 折交叉验证，每轮训练集规模为 $m-1$ ，但需要训练 m 个模型。

注：本题考察留一法的特点与计算代价；见教材 p26-27。

5. 自助法中，包外样本可用于估计模型的测试性能。 ()

参考答案：对。有放回采样后，未出现在训练集中的样本称为包外样本，可用于包外估计。

注：本题考察自助法与包外估计；见教材 p27-28。

6. 在二分类任务中，查准率和查全率通常存在权衡关系，调整阈值可能改变二者取值。 ()

参考答案：对。阈值变化会改变预测为正类的样本集合，进而影响查准率和查全率。

注：本题考察查准率、查全率与阈值选择；见教材 p30-31。

7. 准确率适合所有任务；只要准确率高，就不需要再看其他性能度量。 ()

参考答案：错。类别不平衡或错误代价不同时，准确率可能掩盖关键错误，需要结合查准率、查全率、AUC 或代价敏感指标判断。

注：本题考察准确率的局限及性能度量选择；见教材 p29-36。

8. 若正样本整体排序高于负样本，则 ROC 曲线和 AUC 通常会表现较好。 ()

参考答案：对。AUC 与正、负样本排序质量密切相关，可从排序角度理解分类器性能。

注：本题考察 ROC、AUC 与样本排序质量的关系；见教材 p33-35。

9. 在代价敏感评价中，两个分类器的错误率相同，它们的总代价也一定相同。 ()

参考答案：错。若错在不同类别上，且不同错误代价不同，即使错误率相同，总代价也可能不同。

注：本题考察非均等错误代价下的代价敏感评价；见教材 p35-36。

三、简答题

1. 简要说明经验误差、泛化误差、过拟合和欠拟合之间的关系。

参考答案：经验误差是在训练集上的误差，泛化误差是模型在未见样本上的期望误差。过拟合表现为模型把训练样本学得过于精细，经验误差很低但泛化能力差；欠拟合则是模型连训练样本中的一般规律也未学好，经验误差通常也较高。模型评估与选择的核心目标，是在充分学习规律的同时避免过拟合。

注：本题考察经验误差、泛化误差、过拟合与欠拟合的概念联系；见教材 p23-24。

2. 简要说明偏差、方差与噪声在泛化误差中的含义，并解释为什么模型复杂度过低或过高都可能导致泛化误差较大。

参考答案：偏差刻画学习算法的期望预测与真实结果之间的偏离，偏差大通常说明模型表达能力不足；方差刻画训练集发生变化时学习结果的波动，方差大说明模型对数据扰动较敏感；噪声反映问题本身的不可约误差。模型复杂度过低时，模型难以刻画数据规律，偏差较大，容易欠拟合；模型复杂度过高时，模型可能对训练样本扰动过于敏感，方差增大，容易过拟合。因此模型选择需要在偏差和方差之间取得平衡。

注：本题考察偏差-方差分解及模型复杂度对泛化误差的影响；见教材 p44-46。

3. 比较留出法、 k 折交叉验证和自助法的基本思想，并说明各自适合关注的问题。

参考答案：留出法直接把数据划分为训练集和测试集，简单高效，但一次划分可能带来偶然性，通常需保持分布一致并多次重复。 k 折交叉验证把数据分为 k 个互斥子集，轮流测试并取平均，评估更稳定但训练开销增加；留一法训练集最接近原数据集，但开销最大。自助法通过有放回采样构造训练集，未被抽中的包外样本可用于评估，适合样本量较小、希望减少训练样本规模变化影响的场景。

注：本题考察留出法、交叉验证法、自助法及包外估计的差异；见教材 p25-28。

4. 为什么模型选择时通常要设置验证集？测试集为什么不宜反复用于调参？

参考答案：验证集用于比较候选模型或超参数，使训练过程和模型选择过程有明确依据。测试集的作用是最终估计模型对未见样本的泛化能力；若反复根据测试集表现调参，测试集就参与了模型选择，最终结果会偏向该测试集，测试误差不再是可靠的泛化估计。

注：本题考察验证集、测试集与参数调节之间的边界；见教材 p28。

5. 解释查准率、查全率、 F_1 与 $P-R$ 曲线的含义。为什么在类别不平衡任务中不能只看准确率？

参考答案：查准率衡量被预测为正的样本中有多少是真正例，查全率衡量真正例中有多少被找出。 F_1 是二者的调和平均，用于综合考虑查准率和查全率。 $P-R$ 曲线展示阈值变化时查准率与查全率的关系。类别不平衡时，模型即使忽略少数类也可能得到较高准确率，因此需要关注正类识别质量。

注：本题考察查准率、查全率、 F_1 、 $P-R$ 曲线及类别不平衡下的指标选择；见教材 p29-32。

6. 说明 ROC 曲线、AUC 与代价敏感评价各自解决什么问题。

参考答案：ROC 曲线刻画分类阈值变化时 TPR 与 FPR 的关系，适合观察分类器在不同阈值下的整体表现。AUC 是 ROC 曲线下的面积，可作为排序性能的综合度量。代价敏感评价进一步考虑不同错误的损失差异，当误判正类和误判反类的代价不同，或者不同应用场景代价不同，仅比较错误率或准确率就不够。

注：本题考察 ROC、AUC 与非均等错误代价下的性能评价；见教材 p33–36。

四、计算题

1. 某二分类数据集共有 400 个样本，其中正类 120 个、反类 280 个。

- (1) 若采用 70%/30% 分层留出法，训练集和测试集中正、反类样本数分别是多少？
- (2) 若采用 5 折分层交叉验证，每一折作为测试集时正、反类样本数分别是多少？整个过程需要训练多少个模型？
- (3) 若采用留一法，需要训练多少个模型？每次训练集大小是多少？
- (4) 若采用自助法抽取 400 次，估计包外样本数的期望约为多少？

参考答案：(1) 训练集中正类 $120 \times 0.7 = 84$ 个，反类 $280 \times 0.7 = 196$ 个；测试集中正类 36 个，反类 84 个。

(2) 5 折分层交叉验证中，每折测试集约含正类 $120/5 = 24$ 个、反类 $280/5 = 56$ 个；整个过程训练 5 个模型。

(3) 留一法需要训练 400 个模型，每次用 399 个样本训练、1 个样本测试。

(4) 每个样本未被抽中的概率约为

$$\left(1 - \frac{1}{400}\right)^{400} \approx e^{-1} \approx 0.368.$$

故包外样本数期望约为 $400 \times 0.368 = 147.2$ 个。

注：本题考察分层留出法、 k 折交叉验证、留一法与自助法的样本规模计算；见教材 p25–28。

2. 某二分类器在 200 个测试样本上的混淆矩阵如下：

真实类别	预测结果		
	正类	反类	合计
正类	50	30	80
反类	10	110	120

计算错误率、准确率、查准率、查全率、 F_1 和 F_2 。

参考答案：由表得 $TP = 50$, $FN = 30$, $FP = 10$, $TN = 110$, 总样本数为 200。

$$\text{error} = \frac{FP + FN}{200} = \frac{40}{200} = 0.20, \quad \text{acc} = \frac{TP + TN}{200} = \frac{160}{200} = 0.80.$$

查准率和查全率为

$$P = \frac{TP}{TP + FP} = \frac{50}{60} = \frac{5}{6} \approx 0.833, \quad R = \frac{TP}{TP + FN} = \frac{50}{80} = 0.625.$$

$$F_1 = \frac{2TP}{2TP + FP + FN} = \frac{100}{140} \approx 0.714.$$

当 $\beta = 2$ 时,

$$F_2 = \frac{(1 + 2^2)TP}{(1 + 2^2)TP + 2^2FN + FP} = \frac{250}{250 + 120 + 10} \approx 0.658.$$

注：本题考察混淆矩阵、错误率、准确率、查准率、查全率与 F_β 的计算；见教材 p29-32。

3. 某三分类任务按“一对其余”方式统计得到下表：

类别	TP_i	FP_i	FN_i
A	30	10	5
B	25	5	15
C	40	15	10

按教材中的定义, 计算 $\text{macro-}P$ 、 $\text{macro-}R$ 、 $\text{macro-}F_1$, 以及 $\text{micro-}P$ 、 $\text{micro-}R$ 、 $\text{micro-}F_1$ 。

参考答案：各类查准率、查全率为

$$P_A = \frac{30}{40} = 0.750, \quad R_A = \frac{30}{35} \approx 0.857;$$

$$P_B = \frac{25}{30} \approx 0.833, \quad R_B = \frac{25}{40} = 0.625;$$

$$P_C = \frac{40}{55} \approx 0.727, \quad R_C = \frac{40}{50} = 0.800.$$

因此

$$\text{macro-}P = \frac{0.750 + 0.833 + 0.727}{3} \approx 0.770,$$

$$\text{macro-}R = \frac{0.857 + 0.625 + 0.800}{3} \approx 0.761.$$

按教材公式,

$$\text{macro-}F_1 = \frac{2 \times \text{macro-}P \times \text{macro-}R}{\text{macro-}P + \text{macro-}R} \approx 0.765.$$

微平均先汇总计数： $\overline{TP} = 95$, $\overline{FP} = 30$, $\overline{FN} = 30$ 。故

$$\text{micro-}P = \frac{95}{95 + 30} = 0.760, \quad \text{micro-}R = \frac{95}{95 + 30} = 0.760,$$


$$\text{micro-}F_1 = 0.760.$$

注：本题考察多分类任务中的宏平均、微平均及其 F_1 计算；见教材 p32-33。

4. 某二分类器对 6 个测试样本输出分值如下，分值越大越倾向判为正类。

样本	x_1	x_2	x_3	x_4	x_5	x_6
真实类别	正	反	正	反	正	反
分值	0.90	0.80	0.60	0.50	0.40	0.30

其 ROC 曲线如下图所示。



(1) 写出样本按分值从高到低的正反类序列，并给出 ROC 曲线经过的主要点。

(2) 通过正负样本两两比较计算 AUC。

(3) 计算排序损失 ℓ_{rank} 。

参考答案：(1) 从高到低的类别序列为

正, 反, 正, 反, 正, 反.

共有 3 个正例、3 个反例。阈值依次下移时，ROC 曲线经过

$(0, 0)$, $(0, 1/3)$, $(1/3, 1/3)$, $(1/3, 2/3)$, $(2/3, 2/3)$, $(2/3, 1)$, $(1, 1)$.

(2) 正、负样本两两比较共有 $3 \times 3 = 9$ 对。正样本分值分别为 0.90, 0.60, 0.40，负样本分值分别为 0.80, 0.50, 0.30。其中正样本分值高于负样本的对数为 $3 + 2 + 1 = 6$ ，无并列。因此

$$\text{AUC} = \frac{6}{9} = \frac{2}{3}.$$

(3) 无并列时，排序损失为

$$\ell_{\text{rank}} = 1 - \text{AUC} = \frac{1}{3}.$$

注：本题考察 ROC 曲线构造、AUC 的排序解释以及排序损失；见教材 p33-35。

5. 仍以计算题第 2 题的混淆矩阵为例。若误将正类判为反类的代价为 5，误将反类判为正类的代价为 1，正确分类代价为 0。

(1) 计算该分类器在 200 个样本上的平均代价。

(2) 若另一个分类器的 $FP = 35$ 、 $FN = 5$ ，其错误率与平均代价分别是多少？与第 2 题中的分类器相比，应如何选择？

参考答案：(1) 第 2 题中 $FN = 30$ ， $FP = 10$ 。平均代价为

$$\frac{5 \times FN + 1 \times FP}{200} = \frac{5 \times 30 + 10}{200} = \frac{160}{200} = 0.80.$$

(2) 另一个分类器的错误率为

$$\frac{FP + FN}{200} = \frac{35 + 5}{200} = 0.20,$$

与第 2 题中的分类器相同。但其平均代价为

$$\frac{5 \times 5 + 35}{200} = \frac{60}{200} = 0.30.$$

在给定代价设定下，第二个分类器更合适。这个例子说明，错误率相同并不代表代价相同；当不同错误的损失差异明显时，应使用代价敏感评价。

注：本题考察代价敏感错误率、代价矩阵与非均等错误代价下的模型选择；见教材 p35-36。

6. 某学习算法在三个不同模型复杂度下的平方偏差、方差和噪声估计如下：

模型	平方偏差	方差	噪声
低复杂度模型	0.20	0.03	0.05
中等复杂度模型	0.08	0.08	0.05
高复杂度模型	0.02	0.20	0.05

已知期望泛化误差可分解为“平方偏差 + 方差 + 噪声”。分别计算三个模型的期望泛化误差，并说明应优先选择哪个模型。

参考答案：三个模型的期望泛化误差分别为

$$0.20 + 0.03 + 0.05 = 0.28,$$

$$0.08 + 0.08 + 0.05 = 0.21,$$

$$0.02 + 0.20 + 0.05 = 0.27.$$

低复杂度模型偏差较大，高复杂度模型方差较大；中等复杂度模型在偏差和方差之间更均衡，期望泛化误差最小，因此应优先选择中等复杂度模型。

注：本题考察偏差-方差分解及其在模型复杂度选择中的应用；见教材 p44-46。

密
封
线
内
不
得
答
题