

座位号:

考场号:

学号:

姓名:

题

答

得

不

内

线

封

密



《机器学习》期末考试复习样卷

第四章——决策树

中国科学技术大学 信息科学技术学院

学校: 中国科学技术大学

学院: 信息科学技术学院

学期: 26 春

课程编号: EE3502.01

授课教师: 肖力

助教: 陈璟皓 PB23010359

日期: 2026 年 6 月 18 日

时长: 2 小时

适用说明:

1. 本卷对应第 4 章决策树, 范围为 4.1–4.4; 4.5、4.6 不列入考查。
2. 选择题含单选与多选, 判断题只需判断正误; 简答题重在概念准确、层次清楚, 计算题需写出关键步骤。
3. 默认符号约定与课堂讲义一致。若题中另有说明, 以题中设定为准。

一、选择题

1.1 单选题

1. 【单选】关于决策树的基本结构, 下列说法正确的是 ()。
 - A. 根结点只包含测试样本, 叶结点只包含训练样本
 - B. 每个内部结点对应一个属性测试, 叶结点对应一个预测结果
 - C. 决策树只能处理二分类问题, 不能处理多分类问题
 - D. 从根结点到叶结点的路径不包含任何判定条件

参考答案: B。决策树中内部结点对应属性测试, 分支对应测试结果, 叶结点给出最终类别或预测。

注: 本题考察决策树的结点、分支、路径和叶结点含义; 见教材 p73。

2. 【单选】在递归生成决策树时, 若当前结点中的样本全属于同一类别, 通常应当 ()。
 - A. 停止划分, 并将该结点标记为该类别
 - B. 随机选择一个未用属性继续划分

- C. 删除该结点中的全部样本
- D. 必须改用线性回归模型

参考答案：A。当前样本已经纯净时，不需要继续划分，应生成叶结点并标记为该类别。

注：本题考察决策树基本算法中的递归终止条件；见教材 p74。

3. 【单选】ID3 决策树在选择划分属性时，主要依据 ()。
- A. 信息增益最大
 - B. 信息增益率最小
 - C. 基尼指数最大
 - D. 训练样本编号最小

参考答案：A。ID3 使用信息增益进行属性选择，优先选择信息增益最大的属性。

注：本题考察信息增益准则及 ID3 决策树的属性选择方法；见教材 p75-77。

4. 【单选】信息增益对某类属性存在明显偏好。为缓解这一问题，C4.5 引入的信息增益率主要惩罚的是 ()。
- A. 取值数目较多、划分过细的属性
 - B. 连续属性中的较小阈值
 - C. 类别比例完全均衡的训练集
 - D. 叶结点上的多数类预测

参考答案：A。信息增益偏好取值数目较多的属性；增益率通过固有值项对过细划分进行修正。

注：本题考察信息增益的多取值偏好，以及信息增益率的修正思想；见教材 p77-78。

5. 【单选】CART 决策树使用基尼指数选择划分属性时，倾向于选择 ()。
- A. 基尼指数最大的划分
 - B. 基尼指数最小的划分
 - C. 属性取值个数最多的划分
 - D. 使训练样本数最少的划分

参考答案：B。基尼指数越小，划分后的子集纯度越高，因此 CART 选择使基尼指数最小的属性。

注：本题考察基尼值、基尼指数与 CART 的划分准则；见教材 p79。

6. 【单选】关于剪枝，下列说法正确的是 ()。
- A. 剪枝的主要目的之一是缓解决策树过拟合
 - B. 预剪枝一定比后剪枝得到更大的树
 - C. 后剪枝不需要先生成一棵完整决策树
 - D. 剪枝只能改变叶结点标记，不能改变树结构

参考答案：A。剪枝通过主动去掉部分分支降低模型复杂度，常用于缓解决策树对训练集的过拟合。

注：本题考察剪枝的动机，预剪枝和后剪枝的基本区别；见教材 p79–83。

7. 【单选】设连续属性 a 在当前结点的已排序取值为 0.2, 0.5, 0.9。二分法处理该属性时，候选划分点通常取为 ()。

A. {0.2, 0.5, 0.9} B. {0.35, 0.70} C. {0, 1} D. {0.2, 0.9}

参考答案：B。连续属性的候选划分点通常取相邻排序取值的中点，即 $(0.2+0.5)/2 = 0.35$ 与 $(0.5+0.9)/2 = 0.70$ 。

注：本题考察连续属性离散化，候选划分点集合的构造；见教材 p83–84。

1.2 多选题

8. 【多选】关于决策树学习过程，下列说法正确的有 ()*。

A. 决策树通常自根结点开始递归生成
B. 每个需要继续划分的内部结点选择一个划分属性，将样本分配到不同分支
C. 若当前属性集为空，通常可将结点标记为当前样本中的多数类
D. 叶结点继续执行属性测试，内部结点直接给出类别标记

参考答案：ABC。叶结点给出预测结果，内部结点才执行属性测试。

注：本题考察决策树递归生成过程，内部结点和叶结点的角色；见教材 p73–74。

9. 【多选】关于信息熵与信息增益，下列说法正确的有 ()*。

A. 信息熵可度量样本集合的纯度
B. 样本越纯，信息熵通常越小
C. 信息增益是划分前后不确定性减少的加权度量
D. 信息增益天然完全避免了对多取值属性的偏好

参考答案：ABC。信息增益会偏好取值数目较多的属性，并不天然避免多取值偏好。

注：本题考察信息熵、信息增益及其对多取值属性的偏好；见教材 p75–78。

10. 【多选】关于信息增益率，下列说法正确的有 ()*。

A. 它可看作信息增益除以属性的固有价值
B. 属性划分越细，固有价值通常越大
C. 它一定与信息增益给出完全相同的属性排序
D. C4.5 通常先筛选信息增益不低于平均水平的属性，再比较增益率

参考答案：ABD。增益率修正了信息增益对多取值属性的偏好，因此不一定与信息增益排序相同。

注：本题考察信息增益率公式、固有值含义和 C4.5 的属性选择启发式；见教材 p77-78。

11. 【多选】关于基尼值和基尼指数，下列说法正确的有 ()*。

- A. 基尼值越小，样本集合纯度越高
- B. 若样本集合只含一个类别，则基尼值为 0
- C. 基尼指数是划分后各子集基尼值的加权和
- D. CART 选择划分时倾向于最大化基尼指数

参考答案：ABC。CART 倾向于选择基尼指数最小的划分。

注：本题考察基尼值、基尼指数及 CART 属性选择方向；见教材 p79。

12. 【多选】关于预剪枝与后剪枝，下列说法正确的有 ()*。

- A. 二者都可借助验证集估计划分或剪枝后的泛化效果
- B. 预剪枝在划分前决定是否继续展开结点
- C. 后剪枝通常先生成完整树，再自底向上考察是否替换为叶结点
- D. 预剪枝完全不会带来欠拟合风险

参考答案：ABC。预剪枝可能过早停止划分，因此存在欠拟合风险。

注：本题考察预剪枝和后剪枝的判定时机、验证集作用及风险差异；见教材 p80-83。

13. 【多选】关于连续值和缺失值处理，下列说法正确的有 ()*。

- A. 连续属性可通过候选阈值转化为二分划分
- B. 连续属性在一次划分后，一定不能在后代结点再次使用
- C. 处理缺失值时，可只用该属性取值已知的样本估计划分优劣
- D. 具有缺失值的样本可按权重分配到不同分支，而不是简单丢弃

参考答案：ACD。连续属性不同于离散属性，确定一次阈值后，在后代结点仍可继续作为候选划分属性。

注：本题考察连续属性二分处理、连续属性可重复使用，以及缺失值样本的加权处理；见教材 p83-88。

二、判断题

1. 决策树根结点通常包含训练集中的全部样本。 ()

参考答案：对。决策树生成时从根结点开始，根结点对应整个训练集。

注：本题考察决策树生成过程中的根结点含义；见教材 p73-74。

2. 若当前结点中的样本全属于同一类别，继续划分该结点通常没有必要。（ ）

参考答案：对。此时样本已达到纯净状态，可直接生成叶结点。

注：本题考察决策树递归停止条件；见教材 p74。

3. 信息增益越大，说明使用该属性划分后样本集合纯度提升越明显。（ ）

参考答案：对。信息增益刻画划分后信息熵的减少量，越大通常表示纯度提升越明显。

注：本题考察信息增益的含义和选择方向；见教材 p75-77。

4. 信息增益不存在任何偏好，因此可直接用于所有决策树算法而无需修正。（ ）

参考答案：错。信息增益偏好取值较多的属性，因此 C4.5 使用信息增益率作修正。

注：本题考察信息增益的多取值偏好与信息增益率；见教材 p77-78。

5. 基尼值为 0 表示样本集合中不存在类别混杂。（ ）

参考答案：对。若所有样本属于同一类别，则 $\sum_k p_k^2 = 1$ ，基尼值为 0。

注：本题考察基尼值的纯度含义；见教材 p79。

6. 预剪枝通常能减少训练开销，但若过早停止划分，也可能带来欠拟合。（ ）

参考答案：对。预剪枝在树生成过程中提前停止某些划分，计算开销较小，但可能阻止有用分支展开。

注：本题考察预剪枝的优点与欠拟合风险；见教材 p80-82。

7. 后剪枝先生成完整决策树，再考察是否将某些子树替换为叶结点。（ ）

参考答案：对。后剪枝通常自底向上考察非叶结点，并比较剪枝前后的验证效果。

注：本题考察后剪枝的基本过程；见教材 p82-83。

8. 采用二分法处理连续属性时，候选划分点通常来自相邻排序取值的中点。（ ）

参考答案：对。若连续属性的排序取值为 $a^1, \dots, a^n$ ，候选点通常取 $(a^i + a^{i+1})/2$ 。

注：本题考察连续属性候选划分点的构造；见教材 p83-84。

9. 若样本在某个属性上的取值缺失，就必须将该样本从训练集中删除。（ ）

参考答案：错。缺失值可通过样本权重处理；估计划分优劣时使用取值已知样本，划分样本时可将缺失样本按比例分配到分支。

注：本题考察缺失属性值的加权处理思想；见教材 p85-88。

三、简答题

1. 简述决策树生成的递归过程，并说明哪些情形下应将当前结点标记为叶结点。

参考答案：决策树从根结点开始递归生成。每个结点先检查样本类别和可用属性，再选择一个划分属性，将样本按属性取值分配到子结点，并对子结点重复这一过程。若当前样本全属于同一类别，应标记为该类别叶结点；若属性集为空，或样本在剩余属性上取值相同而无法继续有效划分，通常标记为当前样本中的多数类；若某个分支没有样本，则用父结点样本中的多数类作为该分支叶结点标记。

注：本题考察决策树基本算法、递归生成和三类终止情形；见教材 p73-74。

2. 比较信息增益、信息增益率和基尼指数三种划分准则。答题时应说明它们各自的选择方向及主要特点。

参考答案：信息增益度量划分前后信息熵的减少量，取值越大表示划分后纯度提升越明显，ID3 通常选择信息增益最大的属性；它的主要问题是偏好取值数目较多的属性。信息增益率用信息增益除以属性固有值，可缓解多取值偏好，C4.5 通常先从信息增益不低于平均水平的属性中筛选，再选择增益率较大的属性。基尼指数是划分后各子集基尼值的加权和，值越小表示划分后子集越纯，CART 倾向选择基尼指数最小的划分。

注：本题考察三种划分准则的定义、选择方向和适用算法；见教材 p75-79。

3. 什么是预剪枝和后剪枝？二者在过拟合控制、训练开销和欠拟合风险上有何差异？

参考答案：预剪枝是在决策树生成过程中，对每个候选划分先估计其是否能提升验证集性能；若不能提升，则停止划分并生成叶结点。后剪枝是先生成完整决策树，再自底向上考察非叶结点，若将子树替换为叶结点不降低或能提升验证集性能，则执行剪枝。二者都可降低模型复杂度并缓解过拟合。预剪枝训练开销较小、树较小，但容易过早停止而欠拟合；后剪枝训练开销较大，通常保留更多有用分支，欠拟合风险相对较小。

注：本题考察预剪枝和后剪枝的过程、泛化效果估计及优缺点；见教材 p79-83。

4. 决策树如何处理连续属性和缺失属性值？请分别说明基本思路。

参考答案：连续属性通常采用二分法处理。先将该属性的已知取值排序，以相邻取值的中点作为候选划分点；对每个候选阈值计算划分准则，选择最优阈值，并将样本分为不大于阈值和大于阈值两部分。连续属性在后代结点仍可继续使用。缺失值处理通常分两步：选择划分属性时，只使用该属性取值已知的样本估计划分优劣，并乘以取值已知样本权重比例；执行划分时，取值缺失的样本可按各分支在已知样本中的比例分配权重，而不是直接删除。

注：本题考察连续属性二分划分、候选阈值，以及缺失值下的加权增益和样本分配；见教材 p83-88。

四、计算题

1. 当前结点中共有 10 个样本，其中正类 6 个、反类 4 个。候选属性 A 与 B 的划分结果如下：

属性	分支	正类数	反类数
A	a_1	3	1
A	a_2	2	1
A	a_3	1	2
B	b_1	5	0
B	b_2	1	4

以 $\log_2$ 为底，分别计算 A 、 B 的信息增益、信息增益率和基尼指数，并说明三种准则会选择哪个属性。计算结果保留三位小数。

参考答案：当前结点的信息熵为

$$\text{Ent}(D) = -0.6 \log_2 0.6 - 0.4 \log_2 0.4 = 0.971.$$

属性 A 的划分后条件熵为

$$\frac{4}{10} H\left(\frac{3}{4}, \frac{1}{4}\right) + \frac{3}{10} H\left(\frac{2}{3}, \frac{1}{3}\right) + \frac{3}{10} H\left(\frac{1}{3}, \frac{2}{3}\right) = 0.875,$$

故用未四舍五入的数值计算，有 $\text{Gain}(D, A) \approx 0.095$ 。其固有值为

$$\text{IV}(A) = -0.4 \log_2 0.4 - 0.3 \log_2 0.3 - 0.3 \log_2 0.3 = 1.571,$$

所以 $\text{Gain_ratio}(D, A) = 0.095/1.571 = 0.061$ 。属性 A 的基尼指数为

$$0.4 \left(1 - \left(\frac{3}{4}\right)^2 - \left(\frac{1}{4}\right)^2\right) + 0.3 \left(1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2\right) + 0.3 \left(1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2\right) = 0.417.$$

属性 B 的划分后条件熵为

$$\frac{5}{10} H(1, 0) + \frac{5}{10} H\left(\frac{1}{5}, \frac{4}{5}\right) = 0.361,$$


故 $\text{Gain}(D, B) = 0.610$ 。 $\text{IV}(B) = 1$ ，所以 $\text{Gain_ratio}(D, B) = 0.610$ 。属性 B 的基尼指数为

$$0.5 \cdot 0 + 0.5 \left(1 - \left(\frac{1}{5}\right)^2 - \left(\frac{4}{5}\right)^2\right) = 0.160.$$

信息增益和信息增益率均选择 B ，基尼指数取最小者，也选择 B 。

注：本题考察信息熵、信息增益、信息增益率和基尼指数的完整计算；见教材 p75-79。

2. 图中给出一棵尚未剪枝的候选树。验证集上的统计如下表，其中每一行均表示该结点被考察时，“保留子树”为保留当前子树的验证正确数，“替换为叶结点”为将该结点直接改为多数类叶结点的验证正确数。后剪枝按结点 2、结点 3、结点 1 的顺序自底向上进行；若正确数相同，则选择更简单的叶结点。



后剪枝前的候选树

结点	验证样本数	保留子树正确数	替换为叶结点正确数
2	7	5	6
3	8	7	6
1	20	16	12

判断哪些结点会被剪枝，并给出最终验证集正确率。


参考答案：按自底向上顺序考察。结点 2 保留子树可正确 5 个，替换为叶结点可正确 6 个，剪枝后验证性能更好，因此剪去结点 2 的子树。结点 3 保留子树可正确 7 个，替换为叶结点可正确 6 个，因此保留结点 3 的子树。考察根结点 1 时，保留当前子树可正确 16 个，替换为叶结点可正确 12 个，因此不剪根结点。最终只剪结点 2，验证集正确率为

$$\frac{16}{20} = 80\%.$$

注：本题考察后剪枝的自底向上判定，验证集正确率比较；见教材 p82-83。

3. 连续属性“密度”在当前结点中的取值及类别如下表，并已按数值从小到大排列：

密度	0.20	0.35	0.40	0.55	0.75	0.90
类别	+	+	-	-	-	+



列出所有候选划分点，并用信息增益选择最佳二分阈值。随后考虑另一个属性 M ：在总权重为 10 的样本中， M 取值已知样本的总权重为 8，在已知样本上按 M 划分得到的信息增益为 0.250。计算考虑缺失值后的信息增益，并与属性 N 的信息增益 0.190 比较，说明应优先选择哪个属性。

参考答案：候选划分点为相邻取值的中点：

$$T = \{0.275, 0.375, 0.475, 0.650, 0.825\}.$$

当前正、反类各 3 个，故 $\text{Ent}(D) = 1$ 。逐一计算可得

阈值 t	划分后加权熵	信息增益
0.275	0.809	0.191
0.375	0.541	0.459
0.475	0.918	0.082
0.650	1.000	0.000
0.825	0.809	0.191

因此最佳阈值为 $t = 0.375$ ，划分为“密度 ≤ 0.375 ”与“密度 > 0.375 ”。对缺失值情形，取值已知样本的权重比例为

$$\rho = \frac{8}{10} = 0.8.$$

因此考虑缺失值后的信息增益为

$$\text{Gain}(D, M) = \rho \times 0.250 = 0.200.$$

由于 $0.200 > 0.190$ ，应优先选择属性 M 。

注：本题考察连续属性候选阈值、基于信息增益的最佳阈值选择，以及缺失值下的加权信息增益；见教材 p83–88。