

座位号:

考场号:

学号:

姓名:

题

答

得

不

内

线

封

密



# 《机器学习》期末考试复习样卷

## 第八章——集成学习

中国科学技术大学 信息科学技术学院

学校: 中国科学技术大学

学院: 信息科学技术学院

学期: 26 春

课程编号: EE3502.01

授课教师: 肖力

助教: 陈璟皓 PB23010359

日期: 2026 年 6 月 18 日

时长: 2 小时

### 适用说明:

1. 本卷对应第 8 章集成学习, 范围为 8.1–8.5; 8.6 阅读材料不列入考查。
2. 选择题含单选与多选, 判断题只需判断正误; 简答题重在概念准确、层次清楚, 计算题需写出关键步骤。
3. 默认符号约定与课堂讲义一致。若题中另有说明, 以题中设定为准。

### 一、选择题

#### 1.1 单选题

1. 【单选】关于集成学习, 下列说法最准确的是 ( )。
  - A. 集成学习只适用于同一种学习算法生成的分类器
  - B. 集成学习通过结合多个学习器完成任务, 个体学习器也称基学习器
  - C. 只要增加个体学习器数量, 集成性能必然单调提升
  - D. 集成学习的核心是让所有个体学习器输出完全一致

**参考答案:** B。集成学习通过构建并结合多个学习器完成任务, 个体学习器通常称为基学习器。个体可以同质, 也可以异质; 数量增加本身不能保证性能提升。

**注:** 本题考察集成学习、个体学习器、基学习器、同质与异质集成的基本概念; 见教材 p171。

2. 【单选】若  $T$  个二分类器相互独立, 且每个分类器错误率为  $\epsilon < 0.5$ , 多数投票集成的错误率随  $T$  增大通常会 ( )。
  - A. 逐渐下降, 理想情况下可趋近于零
  - B. 保持为  $\epsilon$ , 与个体数量无关
  - C. 逐渐上升, 因为投票会放大错误
  - D. 一定等于训练集上的平均错误率

参考答案：A。在独立且个体错误率小于 0.5 的理想条件下，多数投票的错误概率可由 Hoeffding 不等式界定，随个体数增加呈指数下降趋势。

注：本题考察多数投票的误差分析，个体准确性与独立性条件；见教材 p172-173。

3. 【单选】AdaBoost 中第  $t$  个基学习器的加权错误率为  $\epsilon_t$ 。在二分类设定下，其权重通常取为 ( )。

A.  $\alpha_t = \epsilon_t / (1 - \epsilon_t)$                       B.  $\alpha_t = 1 - 2\epsilon_t$   
C.  $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$                       D.  $\alpha_t = \ln(1 + \epsilon_t)$

参考答案：C。AdaBoost 通过最小化指数损失得到基学习器权重  $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$ 。当  $\epsilon_t < 0.5$  时， $\alpha_t > 0$ 。

注：本题考察 AdaBoost 中基学习器权重与加权错误率的关系；见教材 p174-175。

4. 【单选】AdaBoost 每轮更新样本权重时，通常会 ( )。

A. 提高被当前基学习器错分样本的权重，降低正确分类样本的权重  
B. 删除所有被错分样本，只保留分类正确的样本  
C. 每轮重新均匀初始化样本权重  
D. 只改变基学习器权重，不改变训练样本权重

参考答案：A。AdaBoost 的重赋权机制使后续基学习器更关注上一轮难以正确分类的样本，这是其逐轮提升性能的重要原因。

注：本题考察 AdaBoost 的重赋权思想与样本分布更新；见教材 p174-177。

5. 【单选】Bagging 对包含  $m$  个样本的训练集进行自助采样，采样集大小仍为  $m$ 。当  $m$  较大时，某个样本未出现在一次采样集中的概率约为 ( )。

A. 0                      B. 0.368                      C. 0.5                      D. 0.632

参考答案：B。一次自助采样中，某样本未被采到的概率为  $(1 - 1/m)^m$ ，当  $m$  较大时趋近于  $e^{-1} \approx 0.368$ 。

注：本题考察 Bagging 的自助采样机制与包外样本比例；见教材 p178-179。


6. 【单选】随机森林相对于普通 Bagging 决策树的主要区别是 ( )。

A. 随机森林不使用自助采样  
B. 随机森林在训练每个结点时随机选择属性子集再划分  
C. 随机森林只能用于回归任务，不能用于分类任务  
D. 随机森林要求所有树具有完全相同的结构

**参考答案：**B。随机森林以 Bagging 为基础，并在决策树结点划分时引入随机属性选择，从而进一步增加个体学习器之间的差异。

**注：**本题考察随机森林的基本思想，随机属性选择与 Bagging 的关系；见教材 p179-180。

7. 【单选】图中三个基学习器给出了不同的分类边界。若它们各自具有一定准确性，集成希望利用的主要性质是 ( )。



- A. 个体学习器的错误完全相同
- B. 个体学习器之间存在适度差异，错误可相互补偿
- C. 每个基学习器都必须是最优分类器
- D. 集成后必须保留某一个固定基学习器的边界

**参考答案：**B。集成学习通常希望个体学习器既有较好准确性，又具有差异性。若错误完全相同，组合难以带来改进。

**注：**本题考察集成学习中准确性与多样性的配合，个体差异对组合效果的作用；见教材 p171-172, 185-188。

8. 【单选】Stacking 的核心做法是 ( )。
- A. 对所有基学习器的输出直接求算术平均
  - B. 用初级学习器的输出作为次级学习器的输入来训练组合模型
  - C. 在每轮训练中只保留错误率最低的基学习器
  - D. 将训练集随机划分为若干互不重叠的子集后分别测试

**参考答案：**B。Stacking 先训练初级学习器，再用它们的预测输出构成次级训练数据，由次级学习器学习如何结合这些输出。

**注：**本题考察学习法结合策略，Stacking 的两层结构与次级学习器；见教材 p183-185。

## 1.2 多选题

9. 【多选】关于集成学习中个体学习器的要求，下列说法正确的有 ( )\*。

- A. 个体学习器应具有一定准确性，不能长期劣于随机猜测
- B. 个体学习器之间最好完全一致，这样投票才稳定
- C. 个体学习器之间需要有差异性，否则组合收益有限
- D. 同质集成与异质集成的区别之一在于基学习器是否属于同一类型

**参考答案：**ACD。有效集成通常要求个体“好而不同”。完全一致的个体学习器相当于重复同一个模型，难以带来实质性提升。

**注：**本题考察集成学习的基本结构，个体准确性、多样性、同质与异质集成；见教材 p171-172。

10. 【多选】关于 Boosting 与 Bagging，下列说法正确的有 ( )\*。

- A. Boosting 通常按序训练基学习器，后一轮会受前一轮结果影响
- B. Bagging 的各基学习器通常可相对独立地训练，便于并行化
- C. Boosting 主要通过重赋权或重采样关注难例
- D. Bagging 每一轮都必须显式提高错分样本权重

**参考答案：**ABC。Bagging 通过自助采样产生训练子集，个体学习器之间通常不按 Boosting 那样逐轮依赖；显式提高错分样本权重是 Boosting 的典型机制。

**注：**本题考察 Boosting 与 Bagging 的训练方式、样本处理方式和并行性差异；见教材 p173-179。

11. 【多选】关于 Bagging 的包外估计，下列说法正确的有 ( )\*。

- A. 包外样本可用于估计泛化误差
- B. 包外样本是某次自助采样中未被选入训练集的样本
- C. 包外估计完全等同于在原训练集上计算训练误差
- D. 包外样本还可用于辅助剪枝、提前停止或特征重要性估计等操作

**参考答案：**ABD。包外样本没有参与相应基学习器训练，因此可提供类似验证集的估计；它不同于直接计算训练误差。

**注：**本题考察包外样本、包外估计及其常见用途；见教材 p178-179。

12. 【多选】关于结合策略，下列说法正确的有 ( )\*。

- A. 回归任务中常用平均法或加权平均法

- B. 分类任务中可使用绝对多数投票、相对多数投票或加权投票  
C. 加权平均和加权投票通常要求权重非负，并常令权重和为 1  
D. 学习法结合策略完全不需要训练数据

**参考答案：**ABC。学习法需要训练次级学习器，因此仍需要数据来学习组合方式。平均法、投票法和学习法分别对应常见回归、分类和更一般的组合思路。

**注：**本题考察平均法、投票法、学习法等结合策略及其适用任务；见教材 p181-185。

13. 【多选】设两个二分类器相对真实标记的正确、错误情况列联表为

|          | $h_j$ 正确 | $h_j$ 错误 |
|----------|----------|----------|
| $h_i$ 正确 | $a$      | $b$      |
| $h_i$ 错误 | $c$      | $d$      |

下列哪些量可用于度量二分类器之间的多样性或相关性 ( )\*。

- A. 不合度量  $dis_{ij} = \frac{b+c}{m}$       B. 相关系数  $\rho_{ij} = \frac{ad-bc}{\sqrt{(a+b)(a+c)(c+d)(b+d)}}$   
C. Q-统计量  $Q_{ij} = \frac{ad-bc}{ad+bc}$       D. 基尼指数  $Gini(D) = 1 - \sum_k p_k^2$

**参考答案：**ABC。不合度量、相关系数和 Q-统计量都可由两个分类器相对真实标记的正确、错误列联表刻画二者差异或相关程度；基尼指数通常用于决策树划分纯度，不是本节给出的成对多样性度量。

**注：**本题考察成对多样性度量，包括不合度量、相关系数与 Q-统计量；见教材 p186-188。

14. 【多选】下列方法有助于增强集成中个体学习器多样性的有 ( )\*。

- A. 对训练样本进行扰动，如自助采样或重采样  
B. 对输入属性进行扰动，如随机选择子空间  
C. 对输出表示进行扰动，如输出翻转或纠错输出码  
D. 固定完全相同的训练集、属性集、参数和随机种子，重复训练同一模型

**参考答案：**ABC。样本扰动、输入属性扰动和输出表示扰动都是常见的多样性增强方式；完全相同设定下重复训练同一模型通常不会带来有效差异。

**注：**本题考察多样性增强的常见路径：数据样本扰动、输入属性扰动和输出表示扰动；见教材 p188-190。

## 二、判断题

1. 若所有基学习器的预测结果完全相同，则简单投票集成与单个基学习器的预测没有本质区别。 ( )

**参考答案：**对。完全一致的个体无法通过投票产生互补效果，集成结果等价于重复同一个预测。

**注：**本题考察个体学习器多样性对集成效果的必要性；见教材 p171-172。

2. AdaBoost 要求每个基学习器的加权错误率小于 0.5，否则对应的  $\alpha_t$  不再为正。 ( )

**参考答案：**对。 $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$ ，当  $\epsilon_t < 0.5$  时为正。

**注：**本题考察 AdaBoost 中基学习器权重的符号与弱学习器条件；见教材 p174-175。

3. Bagging 每轮都根据上一轮的错分样本重新调整训练样本权重。 ( )

**参考答案：**错。这是 Boosting 的典型思路。Bagging 主要通过自助采样生成多个训练子集，各基学习器通常相对独立地训练。

**注：**本题考察 Bagging 与 Boosting 在样本处理机制上的差异；见教材 p173-179。

4. 包外样本没有参与相应基学习器的训练，因此可用于估计该基学习器或集成的泛化性能。 ( )

**参考答案：**对。包外估计利用未进入某次自助采样训练集的样本，能在不额外划分验证集的情况下提供泛化性能估计。

**注：**本题考察包外样本与包外估计的含义；见教材 p178-179。

5. 随机森林只是在 Bagging 之后对所有树做平均，没有在训练基学习器时引入额外随机性。 ( )

**参考答案：**错。随机森林除自助采样外，还在决策树结点划分时随机选择属性子集，从而进一步增强多样性。

**注：**本题考察随机森林相对 Bagging 的额外随机性来源；见教材 p179-180。

6. 相对多数投票要求某一类别获得超过半数票，否则拒绝预测。 ( )

**参考答案：**错。超过半数票是绝对多数投票的要求；相对多数投票选择票数最多的类别，若最高票并列则可随机选取或按规则处理。

**注：**本题考察绝对多数投票与相对多数投票的区别；见教材 p182-183。

7. Stacking 中次级学习器的训练输入通常由初级学习器的预测输出构成，而不是简单重复使用原始属性。 ( )

**参考答案：**对。Stacking 的关键是用初级学习器输出形成次级训练集，再训练元学习器学习组合方式。

**注：**本题考察 Stacking 的次级训练数据构造；见教材 p183-185。



8. 多样性越大, 集成性能就一定越好, 因此个体学习器准确性并不重要。( )

**参考答案:** 错。集成需要“好而不同”的个体。只有差异而没有基本准确性, 组合结果仍可能较差。

**注:** 本题考察准确性与多样性的平衡关系; 见教材 p171-172, 185-188。

### 三、简答题

1. 说明集成学习中“个体学习器”“同质集成”“异质集成”“准确性”和“多样性”的含义, 并解释为什么集成学习强调“好而不同”。

**参考答案:** 个体学习器是参与组合的单个模型, 也称基学习器。同质集成中的个体学习器属于同一种类型, 异质集成则由不同类型的学习器构成。准确性指个体学习器本身应具有一定预测能力; 多样性指个体之间应有差异, 尤其是错误不应完全重合。若个体不够准确, 投票或加权组合会累积无效判断; 若个体完全相同, 组合只是重复同一模型。因此集成学习强调个体既要“好”, 又要“不同”。

**注:** 本题考察集成学习的基本术语, 以及准确性与多样性的配合; 见教材 p171-172。

2. 简述 AdaBoost 的基本流程, 并说明样本权重和基学习器权重各自起什么作用。

**参考答案:** AdaBoost 从均匀样本权重开始, 逐轮训练基学习器。每一轮先根据当前样本分布训练一个基学习器, 再计算其加权错误率, 并由错误率确定该学习器在最终集成中的权重。随后提高被错分样本的权重、降低正确分类样本的权重, 使下一轮更关注难分样本。样本权重用于改变后续训练关注的样本分布, 基学习器权重用于决定最终加权投票或加权求和时每个学习器的影响大小。

**注:** 本题考察 AdaBoost 的逐轮训练、重赋权机制和加性模型思想; 见教材 p173-177。

3. 比较 Bagging 与随机森林。回答时应包括自助采样、包外估计和随机属性选择三个方面。

**参考答案:** Bagging 通过自助采样从原训练集中产生多个训练子集, 分别训练基学习器, 再通过投票或平均结合结果。一次自助采样中约 36.8% 的样本未进入该训练子集, 这些样本可作为包外样本, 用于估计泛化误差或辅助模型选择。随机森林是 Bagging 的一个代表性扩展, 基学习器通常为决策树; 除样本扰动外, 它还在每个结点划分时随机选择属性子集, 再从该子集中选最优划分属性, 从而进一步增强树之间的多样性。

**注:** 本题考察 Bagging、包外估计与随机森林的核心机制; 见教材 p178-180。

4. 概括集成学习中的三类结合策略: 平均法、投票法和学习法, 并分别说明它们适合处理哪类输出。

**参考答案:** 平均法常用于数值型输出, 最简单的是算术平均, 也可根据个体可靠性采用加权平均。投票法常用于分类输出, 包括绝对多数投票、相对多数投票和加权投票; 当学习器输出类别概率时, 也可先处理概率再投票或加权。学习法则不预先固定简单公式, 而是训练一个次级

学习器来学习如何结合初级学习器输出，Stacking 是典型代表。总体上，平均法适合回归或实值输出，投票法适合类别输出，学习法适用于希望由数据自动学习组合规则的情形。

注：本题考察平均法、投票法与学习法的定义、形式和适用场景；见教材 p181–185。

5. 什么是集成学习中的多样性？教材中给出了哪些度量或增强多样性的思路？

参考答案：多样性指集成中个体学习器之间存在差异，特别是它们在样本上的错误模式不完全相同。对于二分类器，可用不合度量、相关系数、 $Q$ -统计量、 $\kappa$ -统计量等成对度量描述两个分类器预测的一致或不一致程度。误差-分歧分解表明，个体误差与个体相对集成输出的分歧共同影响集成误差。增强多样性的常见方法包括数据样本扰动，如自助采样、重采样；输入属性扰动，如随机子空间；输出表示扰动，如输出翻转、纠错输出码；也可通过随机初始化、参数扰动等算法层面的随机性获得差异。

注：本题考察多样性的含义、误差-分歧分解、多样性度量和多样性增强方法；见教材 p185–190。

#### 四、计算题

1. 某二分类训练集有 4 个样本，标记为  $y = (+1, +1, -1, -1)$ 。AdaBoost 初始样本权重均为  $1/4$ 。第一轮基学习器  $h_1$  的预测为

| 样本         | $x_1$ | $x_2$ | $x_3$ | $x_4$ |
|------------|-------|-------|-------|-------|
| $y_i$      | +1    | +1    | -1    | -1    |
| $h_1(x_i)$ | +1    | -1    | -1    | -1    |

第二轮基学习器  $h_2$  在更新后的样本权重下预测为

| 样本         | $x_1$ | $x_2$ | $x_3$ | $x_4$ |
|------------|-------|-------|-------|-------|
| $h_2(x_i)$ | +1    | +1    | +1    | -1    |

求第一轮的  $\epsilon_1$ 、 $\alpha_1$  和更新后的样本权重；再求第二轮的  $\epsilon_2$ 、 $\alpha_2$ ，并给出两轮后的集成分类结果  $H(x) = \text{sign}(\alpha_1 h_1(x) + \alpha_2 h_2(x))$ 。

参考答案：第一轮只有  $x_2$  被错分，故

$$\epsilon_1 = \frac{1}{4}, \quad \alpha_1 = \frac{1}{2} \ln \frac{1 - \epsilon_1}{\epsilon_1} = \frac{1}{2} \ln 3.$$

更新时，错分样本权重乘以  $e^{\alpha_1}$ ，正确样本权重乘以  $e^{-\alpha_1}$ ，归一化后可得

$$D_2 = \left( \frac{1}{6}, \frac{1}{2}, \frac{1}{6}, \frac{1}{6} \right).$$



第二轮中  $h_2$  只错分  $x_3$ , 故

$$\epsilon_2 = \frac{1}{6}, \quad \alpha_2 = \frac{1}{2} \ln \frac{5/6}{1/6} = \frac{1}{2} \ln 5.$$

由于  $\alpha_2 > \alpha_1 > 0$ , 四个样本上的加权符号分别为

$$(+, +, +, -).$$

因此两轮后的集成分类结果为

$$H(x_1) = +1, H(x_2) = +1, H(x_3) = +1, H(x_4) = -1.$$

其中  $x_3$  仍被错分。

**注:** 本题考察 AdaBoost 的加权错误率、基学习器权重、样本权重更新和最终加权投票; 见教材 p174-177。

2. 一个训练集含  $m = 10$  个样本。Bagging 每次自助采样仍抽取 10 次, 并训练一棵决策树; 随机森林在每个结点从  $d = 16$  个属性中随机选择  $k = \lfloor \log_2 d \rfloor$  个候选属性。回答下列问题:

- (1) 某个固定样本在一次自助采样中成为包外样本的概率是多少? 给出数值近似。
- (2) 一次自助采样中, 训练子集包含的不同样本个数的期望是多少?
- (3) 若共训练  $T = 100$  棵树, 某个固定样本期望成为多少棵树的包外样本?
- (4) 随机森林每个结点的候选属性数  $k$  为多少?

**参考答案:** (1) 固定样本每次不被抽中的概率为  $1 - 1/10 = 0.9$ , 连续 10 次都不被抽中的概率为

$$0.9^{10} \approx 0.3487.$$

(2) 对每个样本, 用指示变量表示其是否至少出现一次, 期望不同样本个数为

$$10 \left[ 1 - \left( 1 - \frac{1}{10} \right)^{10} \right] = 10(1 - 0.9^{10}) \approx 6.513.$$

(3) 100 棵树中, 该样本成为包外样本的期望次数为

$$100 \times 0.9^{10} \approx 34.87.$$

(4)  $k = \lfloor \log_2 16 \rfloor = 4$ 。

**注:** 本题考察自助采样的概率计算、包外样本比例和随机森林属性子集大小; 见教材 p178-180。

3. 三个基分类器对 6 个样本的预测如下, 真实标记  $y \in \{+1, -1\}$ 。设加权投票权重为  $w = (0.5, 0.3, 0.2)$ , 若加权得分为 0, 则本题规定预测为  $-1$ 。

密  
封  
线  
内  
不  
得  
透  
题

| 样本    | $x_1$ | $x_2$ | $x_3$ | $x_4$ | $x_5$ | $x_6$ |
|-------|-------|-------|-------|-------|-------|-------|
| $y$   | +1    | +1    | -1    | -1    | +1    | -1    |
| $h_1$ | +1    | +1    | -1    | +1    | +1    | -1    |
| $h_2$ | +1    | -1    | -1    | -1    | +1    | +1    |
| $h_3$ | -1    | +1    | -1    | -1    | +1    | -1    |

- (1) 给出简单多数投票的预测及其错误率。
- (2) 给出加权投票  $H(x) = \text{sign}(\sum_{t=1}^3 w_t h_t(x))$  的预测及其错误率。
- (3) 计算  $h_1$  与  $h_2$  之间的不合度量  $dis_{12}$  和  $Q$ -统计量。

**参考答案：**(1) 简单多数投票逐列取多数，得到

$$(+1, +1, -1, -1, +1, -1),$$

与真实标记完全一致，错误率为 0。

(2) 加权投票得分为

$$(0.6, 0.4, -1.0, 0.0, 1.0, -0.4).$$

按题目规定， $x_4$  处得分为 0 时预测为 -1，因此预测仍为

$$(+1, +1, -1, -1, +1, -1),$$

错误率为 0。

(3) 按两个分类器相对真实标记的正确、错误情况统计： $h_1$  与  $h_2$  都正确的样本有  $x_1, x_3, x_5$ ，故  $a = 3$ ； $h_1$  正确而  $h_2$  错误的样本有  $x_2, x_6$ ，故  $b = 2$ ； $h_1$  错误而  $h_2$  正确的样本有  $x_4$ ，故  $c = 1$ ；二者都错误的样本没有，故  $d = 0$ 。于是

$$dis_{12} = \frac{b+c}{m} = \frac{3}{6} = 0.5,$$

$$Q_{12} = \frac{ad-bc}{ad+bc} = \frac{3 \times 0 - 2 \times 1}{3 \times 0 + 2 \times 1} = -1.$$

这里的列联表统计的是“正确/错误”而不是输出符号本身； $dis_{12} = 0.5$  表明二者在一半样本上的正误状态不同， $Q_{12} = -1$  表明二者的正误模式呈负相关。

**注：**本题考察多数投票、加权投票、平票处理，以及二分类器多样性度量的计算；见教材 p181-188。