

座位号:

考场号:

学号:

姓名:

题

答

得

不

内

线

封

密



《机器学习》期末考试复习样卷

第九章——聚类

中国科学技术大学 信息科学技术学院

学校: 中国科学技术大学

学院: 信息科学技术学院

学期: 26 春

课程编号: EE3502.01

授课教师: 肖力

助教: 陈璟皓 PB23010359

日期: 2026 年 6 月 18 日

时长: 2 小时

适用说明:

1. 本卷对应第 9 章聚类, 考查 9.1–9.3、9.4.1、9.5、9.6; 9.4.2、9.4.3 与 9.7 不列入考查。
2. 选择题含单选与多选, 判断题只需判断正误; 简答题重在概念准确、层次清楚, 计算题需写出关键步骤。
3. 默认距离为欧氏距离, 除非题中另有说明; 涉及集合或簇划分时, 以题中给出的符号为准。

一、选择题

1.1 单选题

1. 【单选】关于聚类任务, 下列说法最准确的是 ()。
A. 聚类必须先给出每个样本的类别标记
B. 聚类将样本划分为若干簇, 使同簇样本尽可能相似、异簇样本尽可能不同
C. 聚类的输出一定等同于真实类别
D. 聚类只能作为监督学习的最后一步

参考答案: B。聚类通常在未标记样本上进行, 目标是根据样本之间的相似性或距离关系形成簇; 簇不一定等同于真实类别。

注: 本题考察聚类任务的目标、簇的含义及其与类别标记的区别; 见教材 p197。

2. 【单选】若评价聚类结果时需要与某个参考模型或外部标记进行比较, 该类指标通常称为 ()。
A. 外部指标 B. 内部指标 C. 距离度量 D. 样本权重

参考答案：A。外部指标将聚类结果与参考划分进行比较；内部指标只利用样本距离和聚类结果本身进行评价。

注：本题考察聚类性能度量中外部指标与内部指标的区分；见教材 p198-199。

3. 【单选】设 a 表示在聚类结果与参考划分中均属于同一簇的样本对数， b 表示在聚类结果中同簇、参考划分中不同簇的样本对数， c 表示在聚类结果中不同簇、参考划分中同簇的样本对数， d 表示在两种划分中均不同簇的样本对数。Jaccard 系数为 ()。

A. $\frac{a}{a+b+c}$ B. $\frac{a+d}{a+b+c+d}$
C. $\sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$ D. $\frac{b+c}{a+d}$

参考答案：A。Jaccard 系数只考察至少在一个划分中被放入同簇的样本对，因此分母为 $a+b+c$ 。

注：本题考察基于样本对计数的外部指标，特别是 Jaccard 系数；见教材 p198。

4. 【单选】关于 DB 指数与 Dunn 指数，下列说法正确的是 ()。
- A. DB 指数越大越好，Dunn 指数越小越好
B. DB 指数越小越好，Dunn 指数越大越好
C. 二者都只适用于有参考标记的数据集
D. 二者都不依赖簇内距离和簇间距离

参考答案：B。DB 指数希望簇内散度小、簇间分离大，因此越小越好；Dunn 指数相反，越大表示簇间分离相对簇内直径更充分。

注：本题考察常用内部指标 DBI 与 DI 的优化方向；见教材 p199。

5. 【单选】在闵可夫斯基距离中， $p=1$ 与 $p=2$ 分别对应 ()。
- A. 欧氏距离、曼哈顿距离 B. 曼哈顿距离、欧氏距离
C. 切比雪夫距离、欧氏距离 D. 余弦距离、曼哈顿距离

参考答案：B。 $p=1$ 时为曼哈顿距离， $p=2$ 时为欧氏距离。

注：本题考察闵可夫斯基距离及其常见特例；见教材 p200。

6. 【单选】 k 均值算法在每一轮更新簇中心时，通常将簇中心置为该簇样本的 ()。
- A. 均值向量 B. 最远样本 C. 任意边界点 D. 类别标记众数

参考答案：A。 k 均值以平方误差为目标，给定簇划分后，令中心为簇内样本均值可使该簇的平方误差最小。

注：本题考察 k 均值算法的中心更新规则及平方误差目标；见教材 p202-203。

7. 【单选】在 DBSCAN 中，若样本 x 的 ε -邻域中至少包含 MinPts 个样本，则 x 称为 ()。
- A. 噪声点 B. 边界点 C. 核心对象 D. 质心

参考答案：C。核心对象的判定只依赖其 ε -邻域内样本数是否不少于 MinPts。

注：本题考察 DBSCAN 中 ε -邻域、核心对象与密度阈值的定义；见教材 p211-212。

8. 【单选】AGNES 是一种层次聚类方法，其基本过程是 ()。
- A. 自顶向下不断拆分簇
- B. 自底向上不断合并最近的簇
- C. 随机初始化中心后迭代更新
- D. 先训练分类器，再给无标记样本赋类标

参考答案：B。AGNES 先将每个样本视为一个簇，然后反复合并距离最近的两个簇，直到达到预设簇数。

注：本题考察 AGNES 层次聚类的凝聚式合并思想；见教材 p214-216。

1.2 多选题

9. 【多选】关于聚类结果 $C = \{C_1, C_2, \dots, C_k\}$ ，下列说法正确的有 ()*。
- A. 不同簇通常互不相交
- B. 所有簇的并集应覆盖样本集
- C. 每个簇都必须预先对应一个已知类别名称
- D. 聚类结果可用于数据压缩、结构发现或作为后续学习的预处理

参考答案：ABD。聚类一般给出样本集的划分，簇名本身没有预先给定的语义；具体语义往往需要结合任务背景解释。

注：本题考察聚类划分的集合形式、簇标记与聚类用途；见教材 p197。

10. 【多选】关于聚类性能度量，下列说法正确的有 ()*。
- A. JC、FMI、RI 都属于外部指标
- B. DBI 和 DI 都属于内部指标

C. RI 的取值越小表示聚类结果越好

D. 外部指标通常需要参考划分, 内部指标通常依赖簇内紧密性和簇间分离性

参考答案: ABD。RI 的取值越大越好; DBI 越小越好, DI 越大越好。

注: 本题考察 JC、FMI、RI、DBI、DI 的类型与评价方向; 见教材 p198-199。

11. 【多选】关于距离计算, 下列说法正确的有 () *。

A. 合法距离度量通常应满足非负性、同一性、对称性和直递性

B. 欧氏距离与曼哈顿距离均可视为闵可夫斯基距离的特例

C. 对离散属性, 可借助 VDM 描述两个属性值之间的差异

D. 对不同重要性的属性, 可引入权重形成加权距离

参考答案: ABCD。连续属性常用闵可夫斯基距离族, 离散属性可用 VDM 处理, 属性重要性不同则可加入权重。

注: 本题考察距离度量的基本性质, 连续属性、离散属性与加权距离的处理; 见教材 p200-201。

12. 【多选】关于 k 均值算法, 下列说法正确的有 () *。

A. 需要事先给定簇数 k

B. 每轮通常包括“按最近中心分配样本”和“按当前簇更新中心”两步

C. 不同初始中心可能导致不同聚类结果

D. 该算法一定能找到全局最优划分

参考答案: ABC。 k 均值的目标函数在迭代中通常不增, 但由于目标非凸, 算法一般只保证收敛到局部结果, 不保证全局最优。

注: 本题考察 k 均值的输入、迭代步骤、初始化敏感性与局部最优问题; 见教材 p202-204。

13. 【多选】关于 DBSCAN, 下列说法正确的有 () *。

A. 需要给定邻域半径 ε 和阈值 MinPts

B. 能把不属于任何簇的样本识别为噪声

C. 只能发现球状簇, 不能处理非凸形状

D. 聚类结果由密度可达与密度相连关系支撑

参考答案: ABD。DBSCAN 的一个特点是可发现形状较任意的密度连通簇, 并能识别噪声; 参数选择会显著影响结果。

注: 本题考察 DBSCAN 的参数、噪声识别能力与密度连通思想; 见教材 p211-214。

14. 【多选】关于 AGNES 中簇间距离的定义，下列说法正确的有 ()*。

- A. 单链接使用两个簇中最近样本之间的距离
- B. 全链接使用两个簇中最远样本之间的距离
- C. 均链接使用两个簇间所有样本对距离的平均值
- D. 三种定义得到的层次结构必然完全相同

参考答案：ABC。单链接、全链接、均链接对簇间距离的定义不同，可能导致不同的合并顺序和层次结构。

注：本题考察 AGNES 中最小距离、最大距离与平均距离三种簇间距离；见教材 p215-216。

二、判断题

1. 聚类通常属于无监督学习，因为训练样本一般没有预先给定的类别标记。

()

参考答案：对。聚类主要依据样本之间的相似性或距离关系形成簇。

注：本题考察聚类与无监督学习的关系；见教材 p197。

2. 外部指标的计算通常需要一个参考划分，而内部指标不需要参考划分。()

参考答案：对。外部指标比较聚类结果与参考模型，内部指标根据聚类结果自身及样本距离评价。

注：本题考察外部指标和内部指标的区别；见教材 p198-199。

3. Dunn 指数越小越好，因为它希望簇间距离尽可能小。()

参考答案：错。Dunn 指数越大越好，它希望簇间最小距离大、簇内最大直径小。

注：本题考察 Dunn 指数的定义方向及其直观含义；见教材 p199。

4. 只要一个函数能衡量样本之间的相似或差异，它就一定满足距离度量的全部性质。

()

参考答案：错。实际任务中可使用不满足严格距离度量性质的相似度或非度量距离，但若称为严格的距离度量，通常需满足非负性、同一性、对称性与直递性。

注：本题考察相似度、距离计算与严格距离度量之间的区别；见教材 p200-201。

5. k 均值算法每轮更新后一定能得到全局最优聚类结果。()

参考答案：错。 k 均值对初始中心敏感，通常只能得到局部结果；多次随机初始化常用于缓解该问题。

注：本题考察 k 均值的局部收敛与初始化敏感性；见教材 p202-204。

6. DBSCAN 中的边界点不必满足核心对象条件, 但可以被某个核心对象密度直达。 ()

参考答案: 对。边界点可能邻域样本数不足 MinPts, 但只要位于某个核心对象的 ε -邻域内, 就可归入相应密度簇。

注: 本题考察 DBSCAN 中核心对象、边界点与密度直达的关系; 见教材 p212。

7. AGNES 的凝聚式过程一旦合并两个簇, 后续不会再把它们拆开。 ()

参考答案: 对。AGNES 自底向上逐步合并簇, 已合并的簇在标准算法中不会回退拆分。

注: 本题考察 AGNES 的自底向上合并过程; 见教材 p214-216。

三、简答题

1. 说明聚类性能度量中外部指标与内部指标的区别, 并各举两个例子。

参考答案: 外部指标需要一个参考划分或外部标记, 将聚类结果与参考结果进行比较, 例如 Jaccard 系数、FMI、RI。内部指标不依赖参考划分, 通常从簇内紧密性和簇间分离性评价聚类质量, 例如 DB 指数和 Dunn 指数。一般而言, JC、FMI、RI 越大越好, DBI 越小越好, DI 越大越好。

注: 本题考察外部指标、内部指标及常用聚类评价指标的含义; 见教材 p198-199。

2. 简述距离度量应满足的基本性质, 并说明欧氏距离、曼哈顿距离和 VDM 分别适合处理什么类型的属性。

参考答案: 严格距离度量通常满足非负性、同一性、对称性和直递性。欧氏距离和曼哈顿距离主要用于连续属性, 二者分别是闵可夫斯基距离在 $p = 2$ 和 $p = 1$ 时的特例。VDM 用于离散属性, 通过比较不同属性值在各类别上的条件分布差异来刻画属性值间距离。若属性重要性不同, 还可引入权重得到加权距离。

注: 本题考察距离度量的性质, 连续属性、离散属性与加权距离的处理; 见教材 p200-201。

3. 写出 k 均值算法的基本步骤, 并说明它的目标函数和两个常见局限。

参考答案: k 均值先给定簇数 k , 随机或按规则初始化 k 个均值向量; 然后反复执行两步: 将每个样本分配给最近的均值向量, 将每个簇的均值向量更新为该簇样本的均值。其目标是最小化簇内平方误差和 $E = \sum_i \sum_{x \in C_i} \|x - \mu_i\|_2^2$ 。常见局限包括需要预先指定 k 、对初始中心和尺度敏感、容易陷入局部最优, 并且更适合近似球状、大小相近的簇。

注: 本题考察 k 均值算法流程、平方误差目标和算法局限; 见教材 p202-204。

4. 解释 DBSCAN 中 ε -邻域、核心对象、密度直达、密度可达和密度相连的含义。

参考答案: ε -邻域是与样本距离不超过 ε 的样本集合。若某样本的 ε -邻域内至少包含 MinPts 个样本, 则它是核心对象。若样本 x_j 位于核心对象 x_i 的 ε -邻域内, 则称 x_j 由 x_i 密度直达。若存在一条由密度直达关系连接的样本链, 则称终点由起点密度可达。若两个样本都可由某个

核心对象密度可达，则二者密度相连。DBSCAN 正是基于密度相连形成簇，并将无法归入任何簇的样本视为噪声。

注：本题考察 DBSCAN 的核心定义及其聚类机制；见教材 p211–213。

5. 简述 AGNES 的基本思想，并比较单链接、全链接和均链接对簇间距离的定义。

参考答案：AGNES 是凝聚式层次聚类方法，先把每个样本看成一个簇，再反复合并距离最近的两个簇，直到达到预设簇数或形成完整层次树。单链接取两个簇中最近样本对的距离，全链接取两个簇中最远样本对的距离，均链接取两个簇间所有样本对距离的平均值。不同定义会影响合并顺序和最终层次结构。

注：本题考察凝聚式层次聚类流程及三种簇间距离定义；见教材 p214–216。

四、计算题

1. 设样本集 $D = \{x_1, x_2, x_3, x_4, x_5, x_6\}$ 。参考划分与某算法得到的聚类结果如下：

划分	第一个簇	第二个簇
参考划分 C^*	$\{x_1, x_2, x_3\}$	$\{x_4, x_5, x_6\}$
聚类结果 C	$\{x_1, x_2, x_4\}$	$\{x_3, x_5, x_6\}$

计算 a, b, c, d ，并求 JC、FMI 和 RI。

参考答案：总样本对数为 $\binom{6}{2} = 15$ 。在两个划分中均同簇的样本对为 (x_1, x_2) 与 (x_5, x_6) ，故 $a = 2$ 。在聚类结果中同簇、参考划分中不同簇的样本对为 $(x_1, x_4), (x_2, x_4), (x_3, x_5), (x_3, x_6)$ ，故 $b = 4$ 。在参考划分中同簇、聚类结果中不同簇的样本对为 $(x_1, x_3), (x_2, x_3), (x_4, x_5), (x_4, x_6)$ ，故 $c = 4$ 。于是 $d = 15 - a - b - c = 5$ 。

$$JC = \frac{a}{a + b + c} = \frac{2}{10} = 0.2,$$


$$FMI = \sqrt{\frac{a}{a + b} \cdot \frac{a}{a + c}} = \sqrt{\frac{2}{6} \cdot \frac{2}{6}} = \frac{1}{3},$$

$$RI = \frac{a + d}{15} = \frac{7}{15}.$$

注：本题考察基于样本对计数的外部聚类指标计算；见教材 p198–199。

2. 对下列二维样本运行 $k = 2$ 的 k 均值算法。初始均值向量为 $\mu_1^{(0)} = (0, 0)$ ， $\mu_2^{(0)} = (10, 10)$ ，距离采用平方欧氏距离。

样本	x_1	x_2	x_3	x_4	x_5	x_6
坐标	(0, 0)	(0, 2)	(2, 0)	(8, 8)	(8, 10)	(10, 8)



密
封
线
内
不
得
答
题

完成一次“分配-更新”迭代：给出两个簇、更新后的均值向量，并计算更新后目标函数 $E = \sum_i \sum_{x \in C_i} \|x - \mu_i\|_2^2$ 。

参考答案：按初始中心分配样本： x_1, x_2, x_3 距离 $\mu_1^{(0)}$ 更近， x_4, x_5, x_6 距离 $\mu_2^{(0)}$ 更近，因此

$$C_1 = \{x_1, x_2, x_3\}, \quad C_2 = \{x_4, x_5, x_6\}.$$

更新均值向量为

$$\mu_1^{(1)} = \left(\frac{2}{3}, \frac{2}{3}\right), \quad \mu_2^{(1)} = \left(\frac{26}{3}, \frac{26}{3}\right).$$

对 C_1 ，平方误差和为

$$\frac{8}{9} + \frac{20}{9} + \frac{20}{9} = \frac{16}{3};$$

对 C_2 ，平方误差和同样为

$$\frac{8}{9} + \frac{20}{9} + \frac{20}{9} = \frac{16}{3}.$$

故更新后目标函数值为

$$E = \frac{32}{3}.$$

注：本题考察 k 均值算法的一轮样本分配、均值更新与平方误差计算；见教材 p202-204。

3. 在一维样本集

$$D = \{0, 0.4, 0.8, 3.0, 3.3, 6.0\}$$

上运行 DBSCAN，取 $\varepsilon = 0.5$ ，MinPts = 2。邻域包含样本自身，距离为普通绝对值距离。判断每个样本是否为核心对象，并给出最终簇与噪声点。

参考答案：各样本的 ε -邻域为

$$N_{\varepsilon}(0) = \{0, 0.4\}, \quad N_{\varepsilon}(0.4) = \{0, 0.4, 0.8\}, \quad N_{\varepsilon}(0.8) = \{0.4, 0.8\},$$

$$N_{\varepsilon}(3.0) = \{3.0, 3.3\}, \quad N_{\varepsilon}(3.3) = \{3.0, 3.3\}, \quad N_{\varepsilon}(6.0) = \{6.0\}.$$

由于 $\text{MinPts} = 2$ ，样本 0, 0.4, 0.8, 3.0, 3.3 均为核心对象，6.0 不是核心对象。由密度可达关系可得两个簇

$$C_1 = \{0, 0.4, 0.8\}, \quad C_2 = \{3.0, 3.3\},$$

样本 6.0 不能由任何核心对象密度可达，因此为噪声点。

注：本题考察 DBSCAN 中 ε -邻域、核心对象、密度可达簇与噪声点的判定；见教材 p211-214。