

座位号:

考场号:

学号:

姓名:

题

答

得

不

内

线

封

密



《机器学习》期末考试复习样卷

第十章——降维与度量学习

中国科学技术大学 信息科学技术学院

学校: 中国科学技术大学

学院: 信息科学技术学院

学期: 26 春

课程编号: EE3502.01

授课教师: 肖力

助教: 陈璟皓 PB23010359

日期: 2026 年 6 月 18 日

时长: 2 小时

适用说明:

1. 本卷对应第 10 章降维与度量学习, 范围为 10.1–10.6; 10.7 不列入考查。
2. 选择题含单选与多选, 判断题只需判断正误; 简答题重在概念准确、层次清楚, 计算题需写出关键步骤。
3. 默认样本按列组成矩阵 $X \in \mathbb{R}^{d \times m}$; 若题中另有说明, 以题中设定为准。

一、选择题


1.1 单选题

1. 【单选】关于 k 近邻学习, 下列说法最准确的是 ()。
 - A. 它先显式训练出一个参数化模型, 再用该模型预测新样本
 - B. 它通常在预测时根据测试样本附近的训练样本标记作出判断
 - C. 它只适用于回归任务, 不适用于分类任务
 - D. 当 k 增大时, 测试误差一定单调下降

参考答案: B。 k 近邻是一种常见的懒惰学习方法, 预测时需要查找测试样本的近邻, 再由近邻标记进行推断。 k 的选择会影响模型复杂度, 但并不保证测试误差单调下降。

注: 本题考察 k 近邻学习的基本思想、懒惰学习特征及 k 的作用; 见教材 p225。

2. 【单选】观察图中同一个测试样本在不同邻域范围下的近邻情况。该图主要说明 ()。



- A. k 近邻分类与距离度量和 k 的取值无关
- B. 只要样本维数较低, k 近邻一定不会出现误分类
- C. 不同的 k 可能使同一测试样本得到不同预测结果
- D. k 近邻必须先把全部样本映射到一维空间

参考答案: C。内圈与外圈对应不同邻域范围, 近邻组成可能发生变化, 因此多数表决结果也可能变化。

注: 本题考察 k 值对近邻集合和预测结果的影响; 见教材 p225。

3. 【单选】若某点处贝叶斯最优分类器的错误率为 $e^* = 1 - P(c^* | x)$, 则在教材给出的渐近分析中, 最近邻分类器在该点处的错误率上界可写为 ()。
- A. 0 B. $e^*/2$ C. e^* D. $2e^*$

参考答案: D。最近邻分类器的错误率可被 $2(1 - P(c^* | x))$ 控制, 即不超过贝叶斯最优错误率的两倍。

注: 本题考察最近邻分类器的错误率上界及其与贝叶斯最优分类器的关系; 见教材 p226。

4. 【单选】关于“维数灾难”, 下列理解正确的是 ()。
- A. 维数升高后, 样本一定会变得线性可分
- B. 维数升高后, 有限样本在空间中往往更加稀疏, 距离计算和邻域估计更困难
- C. 维数升高后, 所有降维算法都不再需要调参
- D. 维数灾难只影响监督学习, 不影响无监督学习

参考答案: B。高维空间中样本分布会变得稀疏, 距离度量与邻域估计的可靠性下降, 这是引入降维的重要动因之一。


注: 本题考察维数灾难的直观含义及其对距离计算、样本稀疏性的影响; 见教材 p226-227。

5. 【单选】多维缩放 (MDS) 的核心目标是 ()。
- A. 在低维空间中尽量保持样本之间的两两距离
 - B. 最大化分类间隔, 并同时学习支持向量
 - C. 直接最大化训练样本的似然函数
 - D. 删除所有方差最大的特征, 只保留方差最小的特征

参考答案: A。MDS 希望在低维表示中尽量保持原空间样本之间的距离关系, 典型做法是由距离矩阵构造内积矩阵并进行特征值分解。

注: 本题考察 MDS 的目标、距离矩阵与低维嵌入之间的关系; 见教材 p227-229。

6. 【单选】观察图中二维样本及两条候选投影方向。主成分分析优先选择实线方向的原因是 ()。



- A. 该方向上的投影方差最大
- B. 该方向上的样本投影全部相同
- C. 该方向必然垂直于所有样本点
- D. 该方向能保留最多的原始坐标轴

参考答案: A。PCA 可从最大化投影方差或最小化重构误差两种角度理解。实线方向是样本变化最明显的方向, 因此对应第一主成分。

注: 本题考察 PCA 的最大方差解释、主成分方向的含义; 见教材 p229-231。

7. 【单选】核主成分分析 (KPCA) 与普通 PCA 的主要区别在于 ()。
- A. KPCA 不允许样本中心化
 - B. KPCA 先将样本映射到高维特征空间, 再利用核函数计算内积并做 PCA
 - C. KPCA 只能处理离散属性, 不能处理连续属性
 - D. KPCA 的投影坐标与训练样本无关

参考答案: B。KPCA 通过核函数避免显式写出高维映射, 在特征空间中进行线性 PCA, 从而实现非线性降维。

注: 本题考察 KPCA 的特征空间思想、核技巧及与 PCA 的关系; 见教材 p232-234。

8. 【单选】关于 Isomap 与 LLE, 下列说法正确的是 ()。

- A. Isomap 先构造近邻图, 再用图上最短路径近似测地线距离
- B. Isomap 要求所有样本之间必须直接相连
- C. LLE 只保持全局欧氏距离, 不考虑局部邻域结构
- D. LLE 的第一步是对核矩阵做特征值分解

参考答案: A。Isomap 用近邻图上的最短路径近似流形上的测地线距离, 再用 MDS 得到低维表示; LLE 则保持局部线性重构关系。

注: 本题考察 Isomap 的测地线距离近似及 LLE 的局部线性思想; 见教材 p234-237。

9. 【单选】度量学习中常用的马氏距离可写为 ()。

- A. $d_M^2(x_i, x_j) = (x_i - x_j)^T M (x_i - x_j)$, 其中 M 通常要求半正定
- B. $d_M^2(x_i, x_j) = x_i^T x_j$, 其中 M 可任意省略
- C. $d_M^2(x_i, x_j) = \|x_i + x_j\|_1$, 其中 M 必须为负定矩阵
- D. $d_M^2(x_i, x_j) = \sum_i x_i$, 只与单个样本坐标和有关

参考答案: A。度量学习常通过学习半正定矩阵 M 来调整不同方向或特征上的距离尺度, $M = PP^T$ 时还可解释为先线性变换再计算欧氏距离。

注: 本题考察马氏距离、半正定矩阵及线性变换解释; 见教材 p238-239。

1.2 多选题

10. 【多选】关于 k 近邻学习, 下列说法正确的有 ()*。

- A. 它的预测通常依赖于训练样本、距离度量和 k 的取值
- B. $k = 1$ 时, 预测只由最近的一个训练样本决定
- C. 若采用不同距离度量, 近邻集合可能发生变化
- D. 在任意数据集上, k 越大泛化性能一定越好

参考答案: ABC。 k 的增大通常会带来更强的平滑效应, 但并不保证泛化性能单调改善。

注: 本题考察 k 近邻的预测机制、距离度量和 k 的影响; 见教材 p225-226。

11. 【多选】关于 MDS, 下列说法正确的有 ()*。

- A. MDS 希望低维空间中的距离尽量接近原空间距离
- B. 经典 MDS 可由距离矩阵构造内积矩阵 $B = Z^T Z$

C. 若 B 的特征值分解为 $V\Lambda V^T$, 常取最大若干特征值对应的特征向量构造低维坐标

D. MDS 必须使用样本类别标记才能运行

参考答案: ABC。MDS 主要依赖样本间距离关系, 不需要类别标记。

注: 本题考察 MDS 的距离保持目标、内积矩阵构造与特征值分解步骤; 见教材 p227-229。

12. 【多选】关于 PCA, 下列说法正确的有 ()*。

A. PCA 通常要求先对样本进行中心化

B. PCA 的一个等价目标是最小化样本到低维子空间的重构误差

C. PCA 的另一个等价目标是最大化低维投影后的方差

D. PCA 选择的是 XX^T 中最小特征值对应的方向作为主要投影方向

参考答案: ABC。PCA 取最大特征值对应的特征向量作为主成分方向; 最小特征值方向对应较小方差。

注: 本题考察 PCA 的中心化、重构误差解释、最大方差解释和特征值分解; 见教材 p229-231。

13. 【多选】关于 KPCA 与流形学习, 下列说法正确的有 ()*。

A. KPCA 通过核函数计算特征空间内积, 可处理某些非线性结构

B. Isomap 用近邻图最短路径近似样本间测地线距离

C. LLE 先在每个样本的邻域内学习线性重构权重, 再在低维空间保持这些权重

D. Isomap 与 LLE 都要求事先给出每个样本的类别标记

参考答案: ABC。KPCA、Isomap 和 LLE 都可用于无监督降维, 并不要求类别标记。

注: 本题考察 KPCA 的核技巧, Isomap 与 LLE 的基本流程; 见教材 p232-237。

14. 【多选】关于度量学习, 下列说法正确的有 ()*。

A. 学习到的距离度量可反映不同属性或方向的重要性

B. 对角矩阵度量可看作对不同属性赋予不同权重

C. 令 $M = PP^T$ 可保证 M 半正定

D. 度量学习的目标只能是让所有样本之间的距离都尽可能小

参考答案: ABC。度量学习通常希望同类或相似样本更近、异类或不相似样本更远, 而不是把所有距离都压小。

注: 本题考察度量学习的动机、加权距离、马氏距离和半正定约束; 见教材 p238-240。

二、判断题

1. k 近邻学习通常没有显式的训练过程，而是在预测阶段利用训练样本进行近邻查询。 ()

参考答案：对。它是懒惰学习的典型例子，主要计算发生在测试样本到来之后。

注：本题考察 k 近邻与懒惰学习的关系；见教材 p225。

2. 最近邻分类器在大样本极限下的错误率一定等于贝叶斯最优错误率。 ()

参考答案：错。教材给出的是上界关系：最近邻错误率不超过贝叶斯最优错误率的两倍，而不是必然相等。

注：本题考察最近邻分类器错误率上界的正确理解；见教材 p226。

3. 降维的一个重要目的，是在尽量保留关键信息的同时缓解高维空间中的样本稀疏与距离失效问题。 ()

参考答案：对。这正是维数灾难背景下降维方法的重要动机。

注：本题考察降维的动机与维数灾难；见教材 p226–227。

4. MDS 的低维表示只由样本类别标记决定，与样本之间的距离无关。 ()

参考答案：错。MDS 直接围绕样本间距离关系构造低维表示，类别标记不是其必要输入。

注：本题考察 MDS 的输入与距离保持目标；见教材 p227–229。

5. 对中心化样本矩阵 X ，PCA 可通过对 XX^T 进行特征值分解得到主成分方向。 ()

参考答案：对。取最大若干特征值对应的特征向量即可构成投影矩阵。

注：本题考察 PCA 的特征值分解求解方法；见教材 p230–231。

6. KPCA 的关键在于显式枚举高维特征空间中的每一个坐标。 ()

参考答案：错。KPCA 的关键是利用核函数计算特征空间内积，从而避免显式构造高维映射。

注：本题考察 KPCA 的核技巧与特征空间内积；见教材 p232–234。

7. Isomap 中近邻图若选取得过密，可能把流形上本应相距较远的点错误连接，从而影响测地线距离估计。 ()

参考答案：对。这类“短路”会使图上最短路径不再可靠地近似流形测地线距离。

注：本题考察 Isomap 近邻图构造及短路问题；见教材 p234–235。

8. LLE 在低维空间中保持的是局部线性重构权重，而不是要求所有两两欧氏距离完全不变。 ()

参考答案：对。LLE 先在原空间邻域内求重构权重，再在低维空间中保持这些权重。

注：本题考察 LLE 的局部线性重构思想；见教材 p236-237。

9. 若 M 不是半正定矩阵，则 $(x_i - x_j)^T M (x_i - x_j)$ 可能为负，因而不宜直接作为平方距离。 ()

参考答案：对。度量学习中通常要求 M 半正定，以保证平方距离非负。

注：本题考察马氏距离中的半正定约束；见教材 p238-239。

三、简答题

1. 简述 k 近邻学习的预测流程，并说明它为什么常被称为“懒惰学习”。

参考答案：对测试样本，先根据给定距离度量在训练集中查找最近的 k 个样本；分类任务通常用多数表决，回归任务可用近邻输出的平均或加权平均。它在训练阶段基本不显式建立判别模型，主要计算推迟到预测阶段完成，因此称为懒惰学习。

注：本题考察 k 近邻学习的流程、分类与回归处理方式以及懒惰学习概念；见教材 p225。

2. 为什么高维数据常需要降维？请从样本稀疏性、距离计算和后续学习三个角度说明。

参考答案：高维空间中有限样本会显得稀疏，局部邻域不再稳定；距离计算也可能失去区分性，使近邻关系和相似性判断不可靠。降维希望在较低维空间中保留主要结构或关键信息，从而降低计算开销，并改善后续分类、聚类或可视化效果。

注：本题考察维数灾难、降维动机及降维对后续学习的作用；见教材 p226-227。

3. 说明 MDS 与 PCA 在目标上的区别和联系。

参考答案：MDS 以保持样本间两两距离为核心目标，通常从距离矩阵出发构造内积矩阵并得到低维坐标。PCA 从原始坐标出发，寻找正交投影方向，使投影方差最大或重构误差最小。二者都可得到低维表示，但 MDS 更强调距离关系的保持，PCA 更强调线性子空间中的方差保留。

注：本题考察 MDS 与 PCA 的目标、输入形式和低维表示含义；见教材 p227-231。

4. 比较 KPCA、Isomap 与 LLE 处理非线性结构的基本思路。

参考答案：KPCA 通过核函数把样本隐式映射到高维特征空间，再在该空间中做 PCA。Isomap 认为流形上的距离应由测地线刻画，因此先构造近邻图，用图上最短路径近似测地线距离，再用 MDS 得到低维表示。LLE 假设每个样本的局部邻域近似线性，先求局部重构权重，再在低维空间中保持这些权重。

注：本题考察 KPCA 的核映射，Isomap 的测地线保持，LLE 的局部线性重构；见教材 p232-237。

5. 什么是度量学习？为什么学习距离度量可能比直接使用欧氏距离更合适？

参考答案：度量学习希望从数据或约束中学习一个适合当前任务的距离度量。欧氏距离默认所有特征同等重要且相互独立，这在实际任务中常不成立。通过学习加权距离或马氏距离，可以放大有判别力的方向、压缩无关方向，使相似样本更近、不相似样本更远，从而改善近邻分类、聚类或检索性能。

注：本题考察度量学习的目的、欧氏距离的局限和马氏距离的任务适应性；见教材 p238-240。

四、计算题

1. 给定二维训练样本如下，使用欧氏距离和多数表决进行 k 近邻分类。测试样本为 $x_* = (2, 2)^T$ 。

编号	x_1	x_2	标记	到 x_* 的距离
1	0	0	A	
2	0	2	A	
3	2	0	A	
4	3	3	B	
5	4	3	B	
6	3	4	B	

分别求 $k = 1, 3, 5$ 时的预测标记，并解释为什么同一个样本可能得到不同结果。

参考答案：各训练样本到 $x_* = (2, 2)^T$ 的距离为

$$\sqrt{8}, \quad 2, \quad 2, \quad \sqrt{2}, \quad \sqrt{5}, \quad \sqrt{5}.$$

由近到远依次为 4(B)、2(A)、3(A)、5(B)、6(B)、1(A)。因此 $k = 1$ 时预测为 B； $k = 3$ 时近邻中 A 有 2 个、B 有 1 个，预测为 A； $k = 5$ 时近邻中 B 有 3 个、A 有 2 个，预测为 B。同一个样本的预测会随 k 改变，是因为邻域范围扩大后参与表决的样本组成发生变化。

注：本题考察 k 近邻距离计算、多数表决和 k 值对预测结果的影响；见教材 p225-226。

2. 设三个样本的两两距离矩阵满足

$$D^2 = \begin{bmatrix} 0 & 1 & 4 \\ 1 & 0 & 1 \\ 4 & 1 & 0 \end{bmatrix},$$

其中 D^2 表示逐元素平方后的距离矩阵。用经典 MDS 构造一维嵌入：

- (1) 计算中心化后的内积矩阵 $B = -\frac{1}{2}HD^2H$ ，其中 $H = I - \frac{1}{3}\mathbf{1}\mathbf{1}^T$ ；
- (2) 取最大特征值对应的一维坐标。

参考答案：该距离矩阵对应一维直线上的三个点。按双中心化计算可得

$$B = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}.$$

矩阵 B 的最大特征值为 2，对应单位特征向量可取

$$v = \frac{1}{\sqrt{2}}(1, 0, -1)^T.$$

因此一维坐标可取

$$z = \sqrt{2}v = (1, 0, -1)^T.$$

整体符号翻转不影响距离保持，所以 $(-1, 0, 1)^T$ 也是等价答案。

注：本题考察经典 MDS 的双中心化、内积矩阵构造和特征值分解嵌入；见教材 p227–229。

3. 给定四个已经中心化的二维样本

$$x_1 = (2, 2)^T, \quad x_2 = (1, 1)^T, \quad x_3 = (-1, -1)^T, \quad x_4 = (-2, -2)^T.$$

令 $X = [x_1, x_2, x_3, x_4]$ 。

(1) 计算 XX^T ；

(2) 求第一主成分方向；

(3) 若降到一维，求四个样本的投影坐标，并给出保留方差比例。

参考答案：有

$$XX^T = \begin{bmatrix} 10 & 10 \\ 10 & 10 \end{bmatrix}.$$

其特征值为 20 和 0，最大特征值对应单位特征向量可取

$$w_1 = \frac{1}{\sqrt{2}}(1, 1)^T.$$

投影坐标为

$$w_1^T x_1 = 2\sqrt{2}, \quad w_1^T x_2 = \sqrt{2}, \quad w_1^T x_3 = -\sqrt{2}, \quad w_1^T x_4 = -2\sqrt{2}.$$

总方差由特征值之和刻画，保留一维后方差比例为

$$\frac{20}{20 + 0} = 1.$$

注：本题考察 PCA 中 XX^T 的特征值分解、主成分方向、投影坐标与方差比例；见教材 p230–231。

4. 考虑三个样本

$$x_1 = (0, 0)^T, \quad x_2 = (1, 0)^T, \quad x_3 = (0, 2)^T,$$

其中 x_1, x_2 属于同一类, x_3 属于另一类。令线性变换矩阵

$$P = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad M = PP^T.$$

(1) 写出 M , 并计算 $d_M^2(x_1, x_2)$ 与 $d_M^2(x_1, x_3)$;

(2) 按 NCA 中的形式, 若只考虑 x_2, x_3 作为 x_1 的候选近邻, 计算 x_1 选择同类样本 x_2 的概率。

参考答案: 首先

$$M = PP^T = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.$$

由 $d_M^2(x_i, x_j) = (x_i - x_j)^T M (x_i - x_j)$, 得到

$$d_M^2(x_1, x_2) = 1, \quad d_M^2(x_1, x_3) = 4.$$

若按 NCA 的邻居选择概率, 且候选邻居只有 x_2, x_3 , 则

$$p_{12} = \frac{\exp(-1)}{\exp(-1) + \exp(-4)} = \frac{1}{1 + \exp(-3)} \approx 0.953.$$

由于 x_2 与 x_1 同类, x_1 被正确分类的概率即为 p_{12} 。该结果体现了学习度量希望同类样本更近、异类样本更远的思想。

注: 本题考察马氏距离计算、 $M = PP^T$ 的半正定构造, 以及 NCA 邻居选择概率; 见教材 p238-239。

密
封
线
内
不
得
答
题