

座位号:

考场号:

学号:

姓名:

题

答

得

不

内

线

封

密



《机器学习》期末考试复习样卷

第十一章——特征选择与稀疏学习

中国科学技术大学 信息科学技术学院

学校: 中国科学技术大学

学院: 信息科学技术学院

学期: 26 春

课程编号: EE3502.01

授课教师: 肖力

助教: 陈璟皓 PB23010359

日期: 2026 年 6 月 18 日

时长: 2 小时

适用说明:

1. 本卷对应第 11 章特征选择与稀疏学习, 范围为 11.1–11.4; 11.5–11.7 不列入考查。
2. 选择题含单选与多选, 判断题只需判断正误; 简答题重在概念准确、层次清楚, 计算题需写出关键步骤。
3. 默认符号约定与课堂讲义一致。若题中另有说明, 以题中设定为准。

一、选择题

1.1 单选题

1. 【单选】在机器学习中进行特征选择, 最主要的目的通常是 ()。
 - A. 保证训练集中的每个样本都能被完全正确分类
 - B. 从原始属性中选出有用特征, 降低维数并缓解无关特征的干扰
 - C. 将所有离散特征统一变为连续特征
 - D. 用特征选择替代模型评估与参数调节

参考答案: B。特征选择通常作为重要的数据预处理过程, 旨在剔除无关或冗余特征, 降低学习难度, 并可能提升模型效率与可解释性。

注: 本题考察特征选择的基本动机, 尤其是维数灾难、无关特征与模型可解释性; 见教材 p247–248。

2. 【单选】关于特征子集搜索，下列说法正确的是 ()。

- A. 前向搜索通常从空集出发，每次加入一个候选特征
- B. 后向搜索通常从空集出发，每次删除一个候选特征
- C. 双向搜索只能在完成穷举搜索后使用
- D. 子集搜索不需要任何评价准则

参考答案：A。前向搜索从空集开始逐步加入特征；后向搜索通常从完整特征集合开始逐步删除特征；双向搜索将二者结合，并不等价于穷举搜索。

注：本题考察前向搜索、后向搜索与双向搜索的基本过程；见教材 p248。

3. 【单选】使用信息增益评价特征子集时，若某个属性划分后得到的各子集越“纯”，则通常意味着 ()。

- A. 条件熵越大，信息增益越小
- B. 条件熵越小，信息增益越大
- C. 训练样本数一定增多
- D. 该属性一定与后续学习器无关

参考答案：B。信息增益为划分前的信息熵减去划分后的加权条件熵；划分后的子集越纯，条件熵越小，信息增益越大。

注：本题考察信息熵与信息增益作为子集评价准则的含义；见教材 p248-249。

4. 【单选】下列方法中，通常属于过滤式特征选择的是 ()。

- A. 先用 Relief 计算特征相关统计量，再选择排名靠前的特征
- B. 对每个候选特征子集都训练最终分类器，并用验证误差决定取舍
- C. 在 LASSO 训练过程中通过 L_1 正则项得到稀疏权重
- D. 通过神经网络反向传播自动调整所有隐藏层参数

参考答案：A。过滤式方法在学习器训练之前对特征进行筛选，Relief 是典型代表；B 属于包裹式思想，C 属于嵌入式思想。

注：本题考察过滤式、包裹式与嵌入式特征选择的区分；见教材 p249-252。


5. 【单选】在 Relief 的思想中，一个特征更有价值，通常表现为它 ()。

- A. 在所有样本上的取值完全相同
- B. 能区分近邻异类样本，同时近邻同类样本之间保持相近
- C. 只在少数噪声样本上出现大幅波动
- D. 与类别无关，但便于绘图

参考答案：B。Relief 通过比较近邻同类样本和近邻异类样本在各特征上的差异来估计特征相关性；能拉开异类、保持同类接近的特征得分更高。

注：本题考察 Relief 中 nearest hit、nearest miss 与特征相关统计量的直观含义；见教材 p249-250。

6. 【单选】图中展示了平方误差等值线与 L_1 、 L_2 约束的几何关系。关于 L_1 正则化更容易产生稀疏解的原因，下列说法最合适的是 ()。



- A. L_1 正则项完全不影响经验误差
B. L_1 约束区域有尖角，等值线更容易在坐标轴附近与其相切
C. L_2 正则项会强制所有权重严格等于零
D. 只要使用 L_1 正则项，就不需要选择正则化参数

参考答案：B。 L_1 约束对应菱形区域，尖角位于坐标轴上；等值线与约束边界相切时更容易使某些坐标为零，因此更容易得到稀疏解。

注：本题考察 L_1 与 L_2 正则化的几何差异，以及 L_1 正则化产生稀疏解的原因；见教材 p252-253。

1.2 多选题

7. 【多选】关于特征选择的作用，下列说法正确的有 ()*。
- A. 可降低维数，从而减轻高维空间中的学习困难
- B. 可在一定程度上去除无关特征，减少对模型训练的干扰
- C. 一定会使任意学习器在任意数据集上的测试性能提升

D. 有助于增强模型可解释性，尤其是在只保留少量关键特征时

参考答案：ABD。特征选择常有助于降维、去除无关特征并提升可解释性，但并不能保证对任意任务和任意学习器都带来性能提升。

注：本题考察特征选择的收益与局限；见教材 p247-248。

8. 【多选】关于子集搜索与子集评价，下列说法正确的有 ()*。

- A. 特征选择可以看作搜索候选特征子集并评价其好坏的过程
- B. 若特征数很大，穷举所有子集通常代价很高
- C. 信息增益可作为一种特征子集评价准则
- D. 贪心式前向搜索必然得到全局最优特征子集

参考答案：ABC。特征选择往往由子集搜索和子集评价组成；穷举复杂度随特征数指数增长；信息增益是常用评价准则之一。贪心搜索高效但不保证全局最优。

注：本题考察特征子集搜索、评价准则与贪心搜索的局限；见教材 p248-249。

9. 【多选】关于 Relief 及 Relief-F，下列说法正确的有 ()*。

- A. Relief 主要面向二分类问题，Relief-F 可处理多分类问题
- B. 最近同类样本和最近异类样本用于估计特征的类别相关性
- C. 特征相关统计量越大，通常表示该特征越值得保留
- D. Relief 必须枚举所有可能的特征子集后才能给出结果

参考答案：ABC。Relief 不是对子集进行穷举搜索，而是根据样本近邻差异为每个特征估计相关统计量；Relief-F 对多分类情形作了扩展。

注：本题考察 Relief 与 Relief-F 的适用场景、统计量含义和计算思路；见教材 p249-250。

10. 【多选】关于 LVW 算法，下列说法正确的有 ()*。

- A. 它属于包裹式特征选择方法
- B. 它用后续学习器的性能来评价候选特征子集
- C. 它采用随机策略搜索特征子集，因此可能受运行时间限制影响
- D. 它完全不需要训练学习器，只需计算特征与类别的相关系数

参考答案：ABC。LVW 是典型包裹式方法，会调用学习器并常用交叉验证误差评价子集；其随机搜索可能在较长时间内仍未找到更优子集。D 更接近某些过滤式方法。

注：本题考察 LVW 的包裹式性质、随机搜索和子集评价方式；见教材 p250-252。

11. 【多选】关于嵌入式特征选择与正则化，下列说法正确的有 ()*。

- A. 嵌入式方法将特征选择与学习器训练过程结合起来
- B. 岭回归中的 L_2 正则化主要抑制权重过大，通常不直接产生稀疏解
- C. LASSO 使用 L_1 正则项，更容易得到部分权重为零的模型
- D. 近端梯度下降可用于处理带 L_1 正则项的优化问题

参考答案：ABCD。嵌入式方法在模型训练中完成特征选择； L_2 正则化主要收缩权重， L_1 正则化更容易产生稀疏解；近端梯度下降是求解含不可导 L_1 项问题的常用方法。

注：本题考察嵌入式特征选择、岭回归、LASSO 与近端梯度下降；见教材 p252-254。

二、判断题

1. 特征选择只在训练结束后进行，与数据预处理无关。 ()

参考答案：错。特征选择通常被看作重要的数据预处理过程，也可以通过嵌入式方法与训练过程结合。

注：本题考察特征选择作为数据预处理过程的地位，以及不同特征选择方式的区别；见教材 p247-248。

2. 若某特征与当前学习任务无关，则保留它可能增加学习器负担，甚至影响泛化性能。 ()

参考答案：对。无关特征可能带来噪声和更高维度的搜索空间，使学习过程更困难。

注：本题考察无关特征与维数灾难对学习过程的影响；见教材 p247-248。

3. 信息增益越大，说明用相应属性划分后获得的类别信息通常越多。 ()

参考答案：对。信息增益度量划分前后信息熵的减少量，值越大表示该划分带来的类别纯度提升越明显。

注：本题考察信息增益的定义与解释；见教材 p248-249。

4. 过滤式方法在评价特征子集时通常直接使用最终学习器的验证误差，因此一定比包裹式方法更慢。 ()

参考答案：错。过滤式方法一般先于学习器训练进行，不直接依赖最终学习器；包裹式方法才通常以学习器性能评价子集，计算代价往往更高。

注：本题考察过滤式与包裹式特征选择在评价方式和计算代价上的差异；见教材 p249-252。

5. LVW 算法若找到与当前最优误差相同但特征数更少的子集，也可以更新当前候选子集。 ()

参考答案：对。LVW 的典型准则是：若误差更低，或误差相同但特征数更少，则接受新的候选子集。

注：本题考察 LVW 算法的更新条件；见教材 p251。

6. L_1 正则化和 L_2 正则化都能抑制模型复杂度，但二者对稀疏性的影响不同。 ()

参考答案：对。二者都通过惩罚权重控制复杂度； L_1 正则化更容易将部分权重压为零，从而产生稀疏解。

注：本题考察 L_1 与 L_2 正则化的共同点和差异；见教材 p252-253。

三、简答题

1. 为什么需要特征选择？请从学习性能、计算代价和模型解释三个角度作答。

参考答案：特征选择可减少无关或冗余特征，使学习器更集中于与任务相关的信息，有助于缓解高维数据带来的学习困难。特征数减少后，训练和预测的计算代价通常下降，模型调参和存储也更容易。若最终只保留少量关键特征，模型结构往往更清晰，便于解释哪些因素真正影响预测结果。需要注意的是，特征选择并不保证在所有任务上都提升性能，其效果取决于数据、学习器和评价准则。

注：本题考察特征选择的动机及其收益边界；见教材 p247-248。

2. 简要比较过滤式、包裹式和嵌入式特征选择方法。

参考答案：过滤式方法在学习器训练前评价特征，通常依据统计量或信息量排序，计算效率较高，但可能忽略学习器自身特性。包裹式方法把后续学习器作为评价器，以验证性能判断子集优劣，通常效果更贴近目标模型，但计算代价较大。嵌入式方法在训练学习器的过程中同时完成特征选择，例如通过正则化使部分权重变为零，兼顾模型学习与特征筛选。

注：本题考察三类特征选择方法的评价依据、计算代价和代表思想；见教材 p249-252。

3. 说明 Relief 方法如何评价一个特征的相关性，并指出 Relief-F 相比 Relief 的主要扩展。

参考答案：Relief 对每个样本寻找最近同类样本和最近异类样本，比较它们在各特征上的差异。若某特征使近邻同类样本差异小、近邻异类样本差异大，则该特征更能区分类别，相关统计量更高。Relief 主要面向二分类问题；Relief-F 将近邻异类样本的比较推广到多分类情形，并结合类别比例对不同类别的贡献加权。

注：本题考察 Relief 的近邻比较思想，以及 Relief-F 对多分类任务的扩展；见教材 p249-250。

4. 为什么 L_1 正则化比 L_2 正则化更容易得到稀疏解？请结合几何直观和优化结果说明。

参考答案：从几何上看， L_1 范数约束区域在坐标轴方向有尖角，经验误差等值线与约束边界首次相切时更容易落在坐标轴上，使某些权重恰为零。 L_2 范数约束区域较圆滑，通常更多表现为将权重整体缩小，而不是直接压为零。因此，LASSO 中的 L_1 正则项常能同时完成参数估计和特征选择；岭回归中的 L_2 正则项则主要起稳定估计、抑制过大权重的作用。

注：本题考察 L_1 与 L_2 正则化的几何解释，以及 LASSO 与岭回归的区别；见教材 p252-253。

四、计算题

1. 给定数据集 D ，共有 10 个样本，其中正类 6 个、反类 4 个。两个候选属性 A 与 B 的划分结果如下表。以信息增益为评价准则，计算 $\text{Gain}(A)$ 与 $\text{Gain}(B)$ ，并判断应优先选择哪个属性。

属性取值	子集规模	正类数	反类数
$A = a_1$	4	3	1
$A = a_2$	3	2	1
$A = a_3$	3	1	2
$B = b_1$	5	5	0
$B = b_2$	5	1	4

参考答案：数据集整体信息熵为

$$\text{Ent}(D) = -0.6 \log_2 0.6 - 0.4 \log_2 0.4 \approx 0.971.$$

对属性 A ，三个子集的熵分别为

$$\text{Ent}(3, 1) \approx 0.811, \quad \text{Ent}(2, 1) \approx 0.918, \quad \text{Ent}(1, 2) \approx 0.918.$$

因此

$$\text{Gain}(A) = 0.971 - \left(\frac{4}{10} \times 0.811 + \frac{3}{10} \times 0.918 + \frac{3}{10} \times 0.918 \right) \approx 0.095.$$

对属性 B ，两个子集的熵分别为 0 与

$$-0.2 \log_2 0.2 - 0.8 \log_2 0.8 \approx 0.722,$$

因此

$$\text{Gain}(B) = 0.971 - \left(\frac{5}{10} \times 0 + \frac{5}{10} \times 0.722 \right) \approx 0.610.$$

由于 $\text{Gain}(B) > \text{Gain}(A)$ ，应优先选择属性 B 。

注：本题考察信息熵、条件熵和信息增益的计算；见教材 p248-249。

2. 设有 4 个样本、2 个离散特征，类别标记如下表。取 $\text{diff}(u, v) = 0$ 表示取值相同， $\text{diff}(u, v) = 1$ 表示取值不同。对每个样本，最近同类样本与最近异类样本已在表中给出。按照

$$\delta^j = \sum_i \left[-\text{diff}(x_i^j, x_{i,\text{nh}}^j)^2 + \text{diff}(x_i^j, x_{i,\text{nm}}^j)^2 \right]$$

计算两个特征的 Relief 相关统计量，并判断哪个特征更重要。

样本	x^1	x^2	类别	最近同类	最近异类
x_1	0	0	+	x_2	x_3
x_2	0	1	+	x_1	x_4
x_3	1	0	-	x_4	x_1
x_4	1	1	-	x_3	x_2

参考答案：对特征 x^1 ，每个样本与最近同类样本在该特征上相同，贡献中的负项均为 0；与最近异类样本在该特征上不同，正项均为 1。因此

$$\delta^1 = 1 + 1 + 1 + 1 = 4.$$

对特征 x^2 ，每个样本与最近同类样本在该特征上不同，负项均为 -1；与最近异类样本在该特征上相同，正项均为 0。因此

$$\delta^2 = -1 - 1 - 1 - 1 = -4.$$

所以特征 x^1 的相关统计量更大，应认为它更重要。

注：本题考察 Relief 特征相关统计量的计算，以及近邻同类与近邻异类的作用；见教材 p249-250。

3. 考虑带 L_1 正则项的近端梯度下降。某一步梯度下降后得到

$$z = w_t - \frac{1}{L} \nabla f(w_t) = (0.60, -0.20, 1.40), \quad \frac{\lambda}{L} = 0.50.$$

根据软阈值更新

$$w_{t+1,j} = \text{sign}(z_j) \max\{|z_j| - \lambda/L, 0\},$$

求 w_{t+1} ，并说明这一更新如何体现稀疏性。

参考答案：逐坐标计算：

$$w_{t+1,1} = 0.60 - 0.50 = 0.10,$$

$$w_{t+1,2} = 0,$$

因为 $|-0.20| < 0.50$ ，该坐标被压为零；

$$w_{t+1,3} = 1.40 - 0.50 = 0.90.$$

因此

$$w_{t+1} = (0.10, 0, 0.90).$$

软阈值更新会把绝对值不超过阈值 λ/L 的坐标直接置零，这正是 L_1 正则化产生稀疏解的重要机制。

注：本题考察近端梯度下降中 L_1 正则项对应的软阈值更新；见教材 p253–254。